SAPP

Sistema de Automatización de Procesamiento

de Pedidos

Universidad Tecnológica Nacional — Facultad Regional Mendoza
Trabajo final de carrera para optar al título de Ingeniero en Informática
Director de Carrera: Alberto Cortez
Mendoza - Argentina
2026

Juan Dario Sinatra, Matias Martinez, Emanuel Ortíz

Declaración de originalidad

Los autores del presente trabajo declaran que su contenido es producto de su labor personal, que no ha sido presentado con anterioridad para la obtención de otro título académico, y que las fuentes consultadas se encuentran debidamente citadas y referenciadas conforme a las normas APA, 7.ª edición. Los autores asumen la responsabilidad por las opiniones vertidas y por la veracidad de los datos reportados.

Juan Darío Sinatra — Matías Martínez — Emanuel Ortíz

Mendoza, Argentina — 2026

Índice de tablas

Tabla 1. Síntesis comparativa de antecedentes analizados

Tabla 2. Características diferenciales de los enfoques de automatización

Tabla 3. Operacionalización de las variables de estudio

Tabla 4. Resultados agregados de la validación ampliada

Tabla 5. Tiempos de procesamiento por pipeline

Tabla 6. Comparación pareada entre el proceso manual y el proceso automatizado

Tabla 7. Errores registrados por tipo, según proceso

Tabla 8. Concordancia entre evaluadores sobre la submuestra verificada

Tabla 9. Registro de excepciones de la validación preliminar

Índice de figuras

Figura **1**. Arquitectura general del sistema SAPP

Figura **2**. Implementación del flujo de automatización en la plataforma n8n

Figura **3**. Diagrama de componentes del sistema SAPP

Figura **4**. Modelo de datos de la capa de persistencia

Lista de acrónimos

AFIP — Administración Federal de Ingresos Públicos

API — Interfaz de Programación de Aplicaciones (Application Programming Interface)

BPA — Automatización de Procesos de Negocio (Business Process Automation)

CSV — Valores Separados por Comas (Comma-Separated Values)

IPA — Automatización Inteligente de Procesos (Intelligent Process Automation)

ISO — Organización Internacional de Normalización (International Organization for Standardization)

JSON — Notación de Objetos de JavaScript (JavaScript Object Notation)

LLM — Modelo de Lenguaje de Gran Escala (Large Language Model)

NLP — Procesamiento de Lenguaje Natural (Natural Language Processing)

OAuth2 — Protocolo de Autorización Abierta, versión 2 (Open Authorization 2.0)

OCR — Reconocimiento Óptico de Caracteres (Optical Character Recognition)

PDF — Formato de Documento Portátil (Portable Document Format)

PyME — Pequeña y Mediana Empresa

ROI — Retorno sobre la Inversión (Return on Investment)

RPA — Automatización Robótica de Procesos (Robotic Process Automation)

SAPP — Sistema de Automatización de Procesamiento de Pedidos

XML — Lenguaje de Marcado Extensible (Extensible Markup Language)

Resumen

La transformación digital ha impulsado a las organizaciones a optimizar sus procesos administrativos con el objetivo de mejorar la eficiencia operativa y la calidad de la información. En este contexto, la presente investigación analiza la implementación de un sistema de automatización inteligente para el procesamiento de pedidos, basado en la integración de automatización de procesos de negocio (BPA), inteligencia artificial para la interpretación de documentos y arquitecturas de integración mediante APIs RESTful.

Se adoptó un diseño de evaluación funcional en entorno controlado, sobre un corpus de veinte documentos comerciales generados de forma sintética por el equipo de investigación, ante la imposibilidad de acceder a un entorno productivo real. Se diseñó, implementó y evaluó un flujo automatizado capaz de procesar pedidos recibidos como documentos PDF adjuntos y como texto en el cuerpo de correos electrónicos.

Se ejecutó una validación ampliada sobre un corpus de veinte documentos comerciales, con valores esperados definidos con anterioridad al procesamiento y verificación campo a campo, que comprendió treinta y dos casos computados entre ambos pipelines. El sistema procesó la totalidad de los documentos sin excepciones atribuibles a su diseño, procesando sin defecto detectado el 71,9 % de los casos y alcanzando una precisión del 97,0 % sobre los campos que el flujo efectivamente persiste, si bien no derivó por sí mismo ningún caso a revisión humana. La validación identificó cinco defectos, localizados en la capa de orquestación y persistencia: un falso positivo que emite confirmación ante correos que no constituyen pedidos, la pérdida del campo de unidad de medida entre la extracción y el registro, la ausencia de un parámetro de temperatura fijado que vuelve la extracción no reproducible, una consulta de búsqueda que no identifica de forma unívoca la planilla de destino, y la

ausencia de correspondencia verificable entre lo que el flujo procesa y lo que comunica, que da lugar a pérdidas silenciosas de pedidos y a la posibilidad de registros duplicados. En contrapartida, el modelo de lenguaje interpretó correctamente la estructura de los pedidos y se abstuvo de completar los campos ausentes en los documentos. Se concluye que la automatización inteligente de procesos constituye una alternativa técnicamente viable para la ingesta de pedidos comerciales en organizaciones pequeñas y medianas, y que el riesgo principal de este tipo de arquitecturas no reside en la capacidad del modelo sino en la ingeniería de orquestación que lo rodea. La comparación pareada con una línea de base del proceso manual, cronometrada sobre diez de los documentos del corpus, arroja una reducción del tiempo de procesamiento del 83,4 %, lo que sostiene la primera hipótesis del trabajo. La magnitud corresponde al tiempo de ejecución del flujo y no a la latencia extremo a extremo, que incorpora el intervalo de consulta del disparador de correo y se acota en la sección 3.3. La segunda hipótesis, referida a la tasa de error, se sostiene con margen estrecho: doce discrepancias sobre cien artículos en el proceso manual frente a ocho en el automatizado. La conclusión es sensible al tratamiento de las diferencias ortográficas, circunstancia que se expone en el análisis de sensibilidad correspondiente. Los errores de uno y otro proceso difieren en naturaleza: el operador humano no cometió errores de cantidad pero sí ortográficos, mientras el sistema conservó la ortografía y registró dos errores de cantidad. Las correcciones derivadas de los hallazgos fueron implementadas y sometidas a una segunda ronda de validación sobre diez casos, ejecutada sobre un proveedor de modelo distinto del original por indisponibilidad sobrevenida de este último. La ronda verifica el cierre de cuatro de los cinco defectos, acota la mitigación del quinto al pipeline de texto, e identifica un modo de falla inverso introducido por la propia corrección del falso positivo: un pedido legítimo sin cantidades numéricas resulta descartado en lugar de registrarse como incompleto. El cambio de proveedor, motivado por el cese de disponibilidad del servicio declarado, constituye en sí mismo un resultado sobre la

reproducibilidad de arquitecturas dependientes de servicios de terceros. Finalmente se proponen lineamientos para la escalabilidad del sistema.

Palabras Claves: Automatización de Procesos de Negocio (BPA), Automatización Inteligente de Procesos (IPA), Modelos de Lenguaje, APIs, Procesamiento de Pedidos.

Abstract

Digital transformation has driven organizations to optimize their administrative processes in order to improve operational efficiency and information quality. In this context, this research analyzes the implementation of an intelligent automation system for order processing, based on the integration of Business Process Automation (BPA), artificial intelligence for document interpretation, and integration architectures using RESTful APIs.

A functional evaluation design in a controlled environment was adopted, using a corpus of twenty commercial documents generated synthetically by means of a Python script, given the lack of access to a real production environment. The documents are not orders from actual organizations: they were produced according to a specification setting ten items per document, diverse commercial categories, and fictitious customer names and addresses. An automated workflow was designed, implemented, and evaluated, capable of processing orders received both as attached PDF documents and as text within the body of email messages. All processing-time figures reported below refer to workflow execution time and not to end-to-end latency, which additionally comprises the polling interval of the email trigger; the distinction is set out in section 3.3.

An expanded validation was conducted on a corpus of twenty commercial documents generated synthetically by the research team, with expected values defined prior to processing and field-by-field verification, comprising thirty-two computed cases across both pipelines. The system processed every document without exceptions attributable to its design, handling 71.9 % of cases without detected defects and achieving 97.0 % accuracy on the fields the workflow actually persists, although it did not itself route any case to human review. The

validation identified five defects in the orchestration and persistence layer: a false positive that issues confirmation for emails that are not orders, the loss of the unit-of-measure field between extraction and recording, the absence of a fixed temperature parameter which renders extraction non-reproducible, a search query that does not uniquely identify the target spreadsheet, and the lack of verifiable correspondence between what the workflow processes and what it communicates, which gives rise to silent order losses and to the possibility of duplicate records. Conversely, the language model correctly interpreted order structure and refrained from filling in fields absent from the source documents. A paired comparison against a manual baseline, timed over ten documents of the corpus, yields an 83.4 % reduction in processing time, supporting the first hypothesis; this figure refers to workflow execution time and not to end-to-end latency, which is qualified in section 3.3. The second hypothesis, concerning error rate, is supported by a narrow margin: twelve discrepancies per hundred items in the manual process against eight in the automated one. The conclusion is sensitive to the treatment of spelling differences, addressed in a corresponding sensitivity analysis. The errors of each process differ in nature: the human operator made no quantity errors but did make spelling errors, whereas the system preserved spelling and produced two quantity errors. It is concluded that intelligent process automation is a technically viable alternative for commercial order ingestion in small and medium-sized organizations, and that the principal risk of such architectures lies not in model capability but in the surrounding orchestration engineering. The corrections derived from the findings were implemented and subjected to a second validation round over ten cases, carried out on a model provider other than the original one owing to the latter becoming unavailable. The round verifies the closure of four of the five defects, restricts the mitigation of the fifth to the text pipeline, and identifies an inverse failure mode introduced by the very correction of the false positive: a legitimate order lacking numerical quantities is discarded rather than recorded as incomplete. The change of provider, prompted by the

discontinued availability of the declared service, is in itself a finding concerning the reproducibility of architectures that depend on third-party services. Finally, guidelines for system scalability are proposed.

Keywords: business process automation, intelligent process automation, large language models, APIs, order processing

Índice

Contenido

Declaración de originalidad 1

Índice de tablas 2

Índice de figuras 2

Lista de acrónimos 3

Resumen 5

Abstract 8

Índice 10

Capítulo 1: Introducción 13

1.1 Contexto del problema 13

1.2 Planteamiento del problema 14

1.3 Justificación 15

1.4 Objetivo general 15

1.5 Objetivos específicos 16

1.6 Alcance y limitaciones 16

Capítulo 2: Marco Teórico 17

2.1 Automatización de procesos de negocio 17

2.2 Automatización inteligente con inteligencia artificial 18

2.3 Integración de sistemas mediante APIs 19

2.4 Impacto organizacional de la automatización 20

2.5 Estado del Arte 20

Nivel 1 — Automatización sin IA: RPA puro 21

Nivel 2 — Automatización híbrida: RPA + OCR 22

Nivel 3 — Automatización cognitiva: RPA + IA + APIs 23

Brecha identificada y posicionamiento del presente estudio 23

2.6 Evolución de la automatización 25

2.7 RPA vs BPA vs IPA 26

2.8 NLP en documentos no estructurados 27

Capítulo 3: Marco Metodológico 28

3.1 Hipótesis de investigación 29

3.2 Variables 30

3.3 Amenazas a la validez 31

Capítulo 4: Desarrollo de la Investigación 35

4.1 Arquitectura general 36

4.2 Pipeline de IA 38

4.3 Diagramas 41

Capítulo 5: Resultados y Análisis 47

5.1 Protocolo y corpus de la validación ampliada 47

5.2 Resultados 50

5.3 Hallazgos 53

5.4 Línea de base del proceso manual 59

5.5 Contraste de las hipótesis 62

5.6 Evaluación independiente y concordancia entre evaluadores 66

5.6.1 Réplica de la evaluación con un evaluador externo al equipo 69

5.7 Limitaciones de la validación 72

5.8 Segunda ronda de validación tras la aplicación de las correcciones 74

5.8.1 Cambio del proveedor del modelo de lenguaje 75

5.8.2 Resultados por defecto 77

5.8.3 Hallazgos de la segunda ronda 78

5.8.4 Alcance de la mitigación del defecto transversal 79

5.8.5 Condiciones de ejecución y limitaciones de esta ronda 80

Capítulo 6: Discusión 82

Capítulo 7: Conclusiones y Recomendaciones 86

Correcciones derivadas de la validación 87

Estado de las correcciones tras su aplicación 89

Integración de trazabilidad inmutable mediante blockchain 93

Manejo autónomo de excepciones mediante agentes de IA generativa 93

Extensión a otros procesos administrativos de alto volumen documental 94

Validación en contextos organizacionales diversos 94

Síntesis final 95

Referencias 96

Anexos 100

Anexo A: Prompts de sistema de las cadenas de extracción 100

Anexo B: Esquemas de salida estructurada 102

Anexo C: Diagramas y capturas del sistema 104

Anexo D: Registro de excepciones de la validación preliminar 108

Capítulo 1: Introducción

1.1 Contexto del problema

La transformación digital ha impulsado a las organizaciones contemporáneas a replantear sus procesos administrativos con el propósito de aumentar la eficiencia operativa, reducir la dependencia de tareas manuales repetitivas y mejorar la calidad de la información generada, permitiendo una toma de decisiones más ágil. Según Westerman et al. (2014), las organizaciones que adoptan estrategias de digitalización maduras registran mejoras en productividad, en agilidad organizacional y en la calidad de la información que circula internamente y hacia los clientes. En el contexto argentino, y particularmente en la región de Cuyo, esta transformación se ha acelerado por la necesidad de competir en mercados globales, donde el volumen de documentos digitales —incluyendo pedidos, facturas, contratos y otros instrumentos comerciales— crece de forma sostenida.

Harmon (2019) sostiene que la automatización de procesos administrativos incide sobre la competitividad de las organizaciones, en particular en entornos caracterizados por grandes volúmenes de información documental y por ciclos de negocio de alta frecuencia. En el sector comercial mendocino, donde las empresas reciben diariamente pedidos en formatos heterogéneos que incluyen documentos PDF, correos electrónicos con adjuntos y pedidos redactados en el cuerpo del mensaje, la dependencia de procesos manuales genera cuellos de botella operativos que afectan la capacidad de respuesta al cliente. Este contexto es el que enmarca el problema que aborda el presente trabajo.

1.2 Planteamiento del problema

La dependencia de procesos manuales constituye un cuello de botella en la gestión administrativa de las organizaciones que procesan documentos comerciales en volumen. De acuerdo con Davenport y Ronanki (2018), una parte significativa del tiempo laboral se destina a tareas repetitivas de manipulación, validación y transcripción de información, lo que genera ineficiencias operativas e incrementa la probabilidad de errores humanos derivados de la fatiga cognitiva y la variabilidad individual. En el contexto específico del procesamiento de pedidos, la manipulación manual de documentos digitales ha sido identificada en la literatura especializada como una fuente de ineficiencia organizacional, asociada a demoras en la cadena de suministro y a mayores costos operativos (Bughin et al., 2018).

En organizaciones de este tipo, el proceso manual de recepción de pedidos suele implicar una secuencia detallada que comienza con la recepción del documento a través de correo electrónico o portal web, continúa con la apertura individual de cada archivo, prosigue con la lectura visual de cada campo relevante —número de pedido, datos del cliente, listado de ítems con cantidades y descripciones, condiciones de entrega—, e incluye el ingreso manual de esos datos en la planilla o sistema de gestión que la organización utilice, hasta culminar con

la confirmación al cliente. La literatura especializada asocia esta secuencia, cuando se sostiene por personal administrativo bajo carga cognitiva constante, con errores de transcripción y con tiempos de procesamiento elevados (Davenport y Ronanki, 2018). El presente trabajo no releva mediciones propias de la tasa de error ni del tiempo de este proceso manual en una organización real: la caracterización precedente describe un proceso de referencia tomado de la literatura, no una medición efectuada por el equipo de investigación. El cronometraje de una muestra propia del proceso manual se reporta en la sección 5.4. Este planteamiento motiva el presente trabajo final y la evaluación de una solución tecnológica de automatización.

1.3 Justificación

La implementación de soluciones de automatización inteligente responde a la necesidad de superar las limitaciones de los procesos manuales de transcripción y de integrar tecnologías digitales e inteligencia artificial en la gestión administrativa. Esta investigación aporta evidencia empírica preliminar, obtenida en entorno controlado, sobre la viabilidad técnica de la hiperautomatización en un proceso administrativo del sector comercial argentino, ofreciendo un modelo de arquitectura documentado y replicable para otras organizaciones, particularmente pymes y medianas empresas donde los recursos tecnológicos y humanos son limitados. Los resultados, junto con el corpus, el protocolo y el flujo publicados, quedan disponibles como referencia para implementaciones posteriores y para su verificación por terceros.

1.4 Objetivo general

El objetivo general de la presente investigación es diseñar, implementar y evaluar, en entorno controlado, un sistema de automatización inteligente para el procesamiento de pedidos administrativos mediante inteligencia artificial e integración por APIs, con el fin de determinar

su viabilidad técnica para reducir la intervención manual en la interpretación de pedidos comerciales heterogéneos.

1.5 Objetivos específicos

Los objetivos específicos que guían el estudio son los siguientes: caracterizar, a partir de la literatura especializada, el proceso manual típico de procesamiento de pedidos y sus principales fuentes de ineficiencia; diseñar un flujo automatizado que integre técnicas de inteligencia artificial para la interpretación de documentos junto con APIs para la persistencia y comunicación entre sistemas; validar el funcionamiento del sistema propuesto en entorno controlado, sobre un corpus de documentos comerciales propio; registrar y documentar los tiempos de procesamiento, la precisión de extracción y las condiciones que activan el escalamiento a revisión manual en la validación funcional; cronometrar una línea de base del proceso manual sobre el mismo conjunto de documentos y contrastar contra ella las hipótesis planteadas; y analizar los resultados obtenidos a la luz de la literatura especializada, extrayendo conclusiones teóricas y recomendaciones prácticas de escalabilidad que puedan ser aplicadas en contextos similares.

1.6 Alcance y limitaciones

El alcance de la investigación se centra en el proceso de recepción, validación y registro de pedidos comerciales, evaluado sobre un corpus de documentos generado por el equipo de investigación. La automatización abarca la interpretación automática de pedidos recibidos como documentos PDF adjuntos y como texto en el cuerpo del correo electrónico, la extracción de datos mediante un modelo de lenguaje, la validación de esquema estructurado y la persistencia de los registros mediante las APIs de los servicios utilizados. No se implementó reconocimiento óptico de caracteres: la extracción opera sobre el texto embebido del

documento. Tampoco se implementó integración con APIs corporativas internas ni procesamiento de documentos en formato XML. No se incluyen dentro del alcance los procesos de facturación electrónica, logística física, pago ni atención post-venta, manteniendo así un foco nítido y gestionable.

Las limitaciones principales radican en que los resultados corresponden a una evaluación funcional en entorno controlado, sobre un corpus generado por el equipo y sin implementación en una organización real, por lo que su generalización deberá realizarse con cautela y considerando el contexto específico de cada organización. Además, los resultados dependen directamente de la calidad de los documentos de entrada (legibilidad, estructura y consistencia) y de la disponibilidad y estabilidad de las APIs de los servicios externos utilizados. Estas limitaciones se declaran de forma explícita y no se consideran resueltas por el diseño adoptado; su tratamiento requiere validación en contextos organizacionales reales. Durante la puesta a punto del sistema se realizaron ajustes iterativos del prompt y del esquema de salida. Esta práctica constituye una amenaza a la validez interna, no una garantía de la misma; su tratamiento se describe en la sección 3.3, donde se detalla la exclusión de los procesamientos de prueba respecto de la muestra analizada.

Capítulo 2: Marco Teórico

2.1 Automatización de procesos de negocio

La Automatización de Procesos de Negocio (BPA) puede definirse como la aplicación sistemática de herramientas digitales para ejecutar procesos organizacionales completos con mínima o nula intervención humana, con efectos sobre la eficiencia, la consistencia, la escalabilidad y la trazabilidad de los procesos. Groover (2020) sostiene que la automatización constituye una evolución de los sistemas productivos hacia entornos completamente digitales

e integrados, donde la tecnología no solo acelera las tareas sino que también transforma la propia naturaleza del trabajo administrativo. En el ámbito organizacional, Harmon (2019) documenta que la automatización permite estandarizar procesos complejos, mejorar la trazabilidad de cada transacción y reducir la variabilidad introducida por el factor humano.

2.2 Automatización inteligente con inteligencia artificial

La incorporación de capacidades avanzadas de inteligencia artificial en procesos administrativos ha dado lugar al concepto más avanzado y transformador de automatización inteligente, también denominado hiperautomatización, que representa un salto cualitativo respecto de la automatización tradicional. Davenport y Kirby (2016) señalan que la convergencia entre las tecnologías tradicionales de automatización y las capacidades cognitivas de la inteligencia artificial representa la base técnica y conceptual de esta nueva etapa, permitiendo que los sistemas no solo ejecuten tareas sino que también interpreten, razonen y tomen decisiones autónomas. Desde el punto de vista técnico, el procesamiento inteligente de documentos combina de manera integral técnicas de aprendizaje automático supervisado y no supervisado, procesamiento del lenguaje natural (NLP), reconocimiento óptico de caracteres (OCR) avanzado y algoritmos de reconocimiento de patrones complejos (Jurafsky & Martin, 2023; Goodfellow et al., 2016). En la práctica, estos modelos son capaces de interpretar documentos no estructurados, validar datos contra reglas de negocio complejas y tomar decisiones sobre contenido semánticamente variable, con niveles de precisión que dependen del dominio, de la calidad del documento de entrada y del diseño de la instrucción suministrada al modelo. Trabajos recientes confirman esta capacidad específicamente para la extracción de información estructurada: Xu et al. (2024) documentan cómo los modelos de lenguaje generativos superan a los enfoques de extracción de información basados en reglas o en

modelos supervisados clásicos, mientras que Dagdelen et al. (2024) demuestran que un modelo de lenguaje ajustado mediante prompts puede convertir texto no estructurado en registros JSON validados sin necesidad de reentrenamiento específico por dominio.

2.3 Integración de sistemas mediante APIs

Las arquitecturas basadas en APIs constituyen un elemento fundamental e insustituible para la integración de sistemas distribuidos en entornos heterogéneos, facilitando el intercambio seguro y eficiente de datos entre aplicaciones que operan sobre plataformas y tecnologías diferentes. Kleppmann (2017) sostiene que los sistemas modernos orientados a datos dependen de manera crítica de flujos de información automatizados y seguros entre servicios interconectados, lo que permite una escalabilidad horizontal y una resiliencia superior. Este enfoque se complementa de manera natural con los patrones de integración empresarial propuestos por Hohpe y Woolf (2004), que establecen principios universales para el intercambio estructurado, confiable y escalable de datos entre aplicaciones heterogéneas, incluyendo patrones clásicos como Message Bus, Content Enricher, Process Manager y Pipes and Filters.

De ese repertorio, el diseño de SAPP se corresponde con el patrón Pipes and Filters: el documento entrante atraviesa una secuencia de etapas de transformación —extracción textual, interpretación semántica, validación de esquema y normalización— en la que cada etapa recibe la salida de la anterior. El enrutamiento por presencia de adjunto responde al patrón Content-Based Router. Los patrones Message Bus y Content Enricher no fueron implementados en la versión evaluada, dado que la arquitectura no contempla una cola de mensajería intermedia ni el enriquecimiento del documento con datos consultados en sistemas externos.

2.4 Impacto organizacional de la automatización

La literatura sobre adopción de automatización documenta cambios en la organización del trabajo, que alcanzan a los roles, los procesos y las prácticas internas. El informe del McKinsey Global Institute (Bughin et al., 2018) modela el impacto macroeconómico de la adopción de inteligencia artificial y proyecta una contribución significativa al producto bruto global hacia 2030, en un escenario de reconfiguración de roles laborales y estructuras organizativas. Trasladado al contexto argentino, ese escenario supondría capacitar al personal en competencias de supervisión, manejo de excepciones y gobernanza tecnológica, y la aparición de puestos ligados a la gestión de sistemas automatizados. El presente trabajo no releva evidencia propia sobre estos efectos organizacionales.

2.5 Estado del Arte

La revisión de la literatura se realizó sobre las bases de datos Scopus, IEEE Xplore, ACM Digital Library y Google Scholar, con el período de búsqueda comprendido entre enero de 2015 y diciembre de 2025. Los términos de búsqueda utilizados fueron, en inglés: ("robotic process automation" OR "hyperautomation") AND ("document processing" OR "order management") AND ("artificial intelligence" OR "NLP" OR "OCR"). Los criterios de inclusión fueron: estudios empíricos o de caso con métricas cuantificables, publicados en revistas arbitradas o conferencias indexadas, con acceso completo al texto. La búsqueda se desarrolló como revisión narrativa y no como revisión sistemática, dado que no se aplicó un protocolo PRISMA ni se documentó el proceso de cribado con el detalle que ese tipo de revisión exige. De los antecedentes identificados, se analizan en profundidad los cuatro más directamente comparables con el presente estudio en términos de tecnología aplicada, tipo de proceso automatizado y contexto organizacional.

El campo de la automatización de procesos administrativos ha evolucionado significativamente en la última década, impulsado por la convergencia entre RPA, inteligencia artificial y arquitecturas orientadas a servicios. La revisión identifica tres niveles de madurez tecnológica en los antecedentes relevantes, que se analizan a continuación en orden creciente de complejidad.

Nivel 1 — Automatización sin IA: RPA puro

En el primer nivel se ubican las implementaciones de RPA sobre procesos estructurados con baja variabilidad documental. Lacity y Willcocks (2016) documentan el caso más citado de este enfoque en Telefónica O2, donde la automatización robótica de tareas administrativas repetitivas produjo beneficios operativos y económicos verificables, reportados por los autores en términos de retorno de la inversión y de beneficio neto anual. Los autores destacan que el éxito de la implementación dependió críticamente de la estandarización previa del proceso y de la estabilidad de las interfaces de usuario sobre las que operaba el robot. Esta condición es determinante para comprender el alcance y las limitaciones del enfoque: el RPA puro no tolera variabilidad documental ni formatos heterogéneos entre distintos emisores.

Complementando este caso, Costa et al. (2022) realizaron una revisión sistemática de la literatura sobre adopción de RPA que sintetiza los resultados de múltiples implementaciones en distintos sectores organizacionales. Los autores identifican que los procesos más aptos para automatización robótica comparten tres características centrales: alta repetitividad, basados en reglas explícitas y con baja variabilidad en los documentos de entrada. Si bien los beneficios documentados incluyen la liberación de empleados hacia tareas de mayor valor agregado y la reducción sostenida de errores operativos, los autores señalan como limitación estructural la incapacidad del RPA tradicional para procesar documentos no estructurados ni gestionar variabilidad semántica entre distintos emisores.

En línea con estos hallazgos, Pramod (2022) realizó una revisión sistemática de 113 artículos mediante metodología PRISMA con el objetivo de mapear el estado de adopción de RPA por industria. Los resultados evidencian que la tecnología ha sido ampliamente adoptada en el sector bancario y financiero, con presencia moderada en salud y manufactura, mientras que numerosos dominios industriales permanecen sin explorar. El autor identifica como desafío transversal la dificultad de determinar qué tareas son elegibles para automatización en cada contexto específico, y postula que las oportunidades más significativas se encuentran en los sectores que aún no han aprovechado los avances tecnológicos disponibles. El sector comercial de PyMEs latinoamericanas, objeto del presente estudio, se inscribe en esta categoría de dominios inexplorados, lo que refuerza la pertinencia y originalidad del aporte realizado.

Nivel 2 — Automatización híbrida: RPA + OCR

El segundo nivel incorpora reconocimiento óptico de caracteres para extender el alcance de la automatización a documentos escaneados, superando parcialmente la limitación del RPA puro frente a contenido no digital. Este enfoque permite procesar imágenes de documentos y extraer campos predefinidos mediante plantillas fijas. Sin embargo, la dependencia de estructuras documentales estables limita severamente su aplicabilidad en entornos con alta variabilidad de formatos entre distintos emisores, como es el caso del sector comercial mendocino donde cada proveedor utiliza su propio formato de orden de compra. Jurafsky y Martin (2023) desarrollan los fundamentos del procesamiento del lenguaje natural que explican la sensibilidad de los sistemas de reconocimiento óptico sin componente semántico ante la calidad de la imagen de origen y la variación estructural del documento. La caracterización específica de la variabilidad léxica del español comercial no proviene de esa obra: se enuncia en este trabajo a partir de las condiciones observadas en el corpus construido para la validación.

Nivel 3 — Automatización cognitiva: RPA + IA + APIs

El tercer nivel, denominado Hiperautomatización por Davenport y Kirby (2016), integra modelos de lenguaje o aprendizaje automático con la infraestructura de automatización, habilitando el procesamiento de documentos no estructurados que requieren interpretación contextual. Este enfoque representa un salto cualitativo respecto de los niveles anteriores porque el sistema no solo ejecuta tareas, sino que interpreta, normaliza y toma decisiones sobre contenido semánticamente variable. Jurafsky y Martin (2023) desarrollan los fundamentos del procesamiento de lenguaje natural aplicado a la extracción de información sobre texto no estructurado. Cabe señalar que la obra citada no reporta umbrales de precisión para el escenario específico aquí abordado, ni caracteriza la variabilidad léxica del español comercial latinoamericano; ambas cuestiones se enuncian en este trabajo como supuestos de contexto y no como resultados atribuibles a esa fuente. El presente estudio se posiciona en este tercer nivel, adoptando prompt engineering estructurado sobre Mistral Cloud Chat como alternativa viable al fine-tuning clásico en un entorno con corpus anotados limitados.

Brecha identificada y posicionamiento del presente estudio

La revisión de los antecedentes permite identificar con precisión la brecha que el presente trabajo viene a cubrir. Los estudios de nivel 1 demuestran la viabilidad del RPA en procesos estructurados pero no abordan la variabilidad documental. Los de nivel 2 extienden el alcance mediante OCR pero mantienen la dependencia de plantillas fijas. Los de nivel 3 habilitan la interpretación semántica pero se desarrollan mayoritariamente en contextos anglosajones con alta disponibilidad de corpus anotados. A nivel regional, la revisión no identificó evaluaciones funcionales documentadas y reproducibles —esto es, acompañadas de la publicación del corpus, del protocolo de medición y del flujo implementado— de arquitecturas que integren simultáneamente orquestación de flujos, modelos de lenguaje de

gran escala y APIs de persistencia para la ingesta de pedidos comerciales redactados en español. Los trabajos relevados reportan resultados sin poner a disposición los artefactos que permitirían replicarlos. Esta brecha, y no la ausencia de implementaciones en producción, es la que el presente trabajo se propone atender: su aporte reside en la publicación conjunta del corpus, el protocolo, el registro por caso y el flujo exportado, de modo que un tercero pueda repetir la evaluación y contrastar sus resultados.

El presente trabajo se posiciona en el tercer nivel. La Tabla 1 sintetiza los antecedentes analizados.

Tabla 1

Síntesis comparativa de antecedentes analizados

Trabajo	Tecnología	Reducción de Tiempo	Limitaciones
Lacity & Willcocks (2016)	RPA	Reportado como ROI y beneficio neto	No incluye IA
Davenport & Kirby (2016)	Hiperautomatización	Conceptual	Sin validación empírica
Costa et al. (2022)	RPA (múltiples casos)	Variable según caso	No gestiona documentos no estructurados ni variabilidad semántica
Pramod (2022)	RPA (113 casos, múltiples industrias)	Variable según sector	Sectores comerciales y PyMEs sin explorar
Presente Estudio	BPA/IPA + LLM + APIs	83,4 % del tiempo de procesamiento (comparación pareada)	Validación funcional en entorno controlado; corpus sintético de 20 documentos

Nota. Elaboración propia a partir de la revisión narrativa de antecedentes.

2.6 Evolución de la automatización

La automatización de procesos ha atravesado tres estadios evolutivos claramente diferenciados. El primero, basado en reglas explícitas (BPA), permitió estandarizar procesos estructurados, pero carecía de capacidad para gestionar variabilidad o excepciones no anticipadas. El segundo, la automatización robótica de procesos (RPA), extendió ese alcance permitiendo operar sobre interfaces de usuario existentes sin modificar los sistemas

subyacentes, reduciendo significativamente los costos de integración (Lacity & Willcocks, 2016). El tercer estadio, denominado Hiperautomatización por Davenport y Kirby (2016), integra RPA con inteligencia artificial y arquitecturas distribuidas, habilitando la automatización de procesos no estructurados que requieren interpretación contextual. El sistema SAPP se inscribe en este tercer nivel, combinando los tres paradigmas de manera complementaria.

Este paradigma fue identificado por Gartner (2020) como una de las diez tendencias tecnológicas estratégicas de mayor impacto para las organizaciones en la década siguiente.

2.7 RPA vs BPA vs IPA

La distinción entre estos enfoques no es meramente terminológica sino funcional: determina qué tipos de procesos pueden automatizarse, qué nivel de variabilidad tolera el sistema y qué infraestructura técnica requiere. Groover (2020) señala que la elección del paradigma de automatización debe estar guiada por las características del proceso objetivo y no por la disponibilidad de herramientas. La Tabla 2 sintetiza las características diferenciales de cada enfoque en relación con el presente estudio.

Tabla 2

Características diferenciales de los enfoques de automatización

Enfoque	Característica	Limitación
BPA	Automatización estructurada	Baja flexibilidad
RPA	Automatización de interfaz	Dependencia de UI
IPA	Integración con IA	Complejidad técnica

Hiperautomatización	Integración total	Alto costo inicial

Nota. Elaboración propia.

2.8 NLP en documentos no estructurados

Los modelos de procesamiento del lenguaje natural enfrentan desafíos específicos cuando se aplican a documentos comerciales heterogéneos. Krieger et al. (2023) documentan, para el dominio de facturas de proveedores heterogéneos, que la variación de formato entre emisores distintos constituye la principal dificultad para la extracción automática de información. A esa fuente de degradación se suman, en los documentos considerados en este trabajo, la eventual presencia de documentos escaneados sin texto embebido y la variabilidad léxica del español comercial rioplatense, ambas condiciones observadas en el corpus construido para la validación y no tomadas de la literatura. Estas limitaciones impactan en la precisión de la extracción de entidades y explican la adopción de modelos ajustados sobre corpus de dominio específico en lugar de modelos genéricos preentrenados. En el presente trabajo se adoptó un enfoque de prompt engineering estructurado sobre un modelo de instrucción (Mistral Cloud Chat) en lugar de fine-tuning clásico, dado que la disponibilidad de corpus anotados era limitada para este dominio específico. Este tipo de dificultad es consistente con lo reportado por Krieger et al. (2023), quienes muestran que la extracción automática de información en facturas de proveedores heterogéneos exige superar variaciones de formato similares a las del presente corpus, y con Liu et al. (2024), quienes documentan la transición de los métodos de extracción de información basados en reglas hacia los basados en modelos de lenguaje de gran escala. Chen et al. (2025) muestran además que la calidad del prompt utilizado incide directamente en la precisión de extracción de campos en documentos comerciales, lo que respalda la decisión metodológica de este trabajo de iterar sobre el diseño del prompt en lugar de tratarlo como un parámetro fijo.

Capítulo 3: Marco Metodológico

La investigación es de tipo aplicada y de enfoque mixto, con predominio cuantitativo en la medición precisa de tiempos de procesamiento y tasas de precisión en la extracción de entidades, y cualitativo en el análisis de la experiencia de implementación y de los logs del sistema. Se adoptó un diseño de evaluación en entorno controlado sobre un corpus de veinte documentos comerciales generados de forma sintética por el equipo de investigación. Este diseño fue seleccionado en función de las restricciones de acceso a entornos productivos reales durante el período de implementación. La variabilidad introducida en el corpus es de orden léxico y de unidades de medida, no de maquetación ni de formato de origen: los veinte documentos comparten una misma estructura de encabezado y de listado de ítems. El diseño constituye, en consecuencia, una evaluación funcional del sistema sobre entradas de estructura regular, y no una evaluación en condiciones de variabilidad documental equiparable a la de un entorno productivo, limitación cuyas consecuencias se declaran en la sección 5.7.

Las técnicas de obtención de datos incluyeron: generación sintética de los documentos comerciales que conforman el corpus de evaluación; registro automático de tiempos de procesamiento mediante los logs de ejecución de n8n; verificación manual de la precisión de extracción comparando el JSON generado por el sistema contra el documento original campo por campo, y la medición cronometrada del tiempo de procesamiento manual sobre una muestra del mismo corpus, destinada a construir la línea de base de comparación. Esta medición se ejecutó sobre diez documentos del corpus y sus resultados se reportan en la sección 5.4.

Las herramientas tecnológicas utilizadas fueron: n8n en modalidad autoalojada como plataforma de orquestación de flujos de automatización; el modelo de lenguaje Mistral Cloud

Chat accedido mediante su API oficial para la extracción inteligente de entidades; Google Drive para el almacenamiento y trazabilidad de documentos originales; Google Sheets como capa de persistencia estructurada de los pedidos procesados; y la API de Gmail como mecanismo de trigger para la detección de nuevos pedidos entrantes.

El procedimiento se estructuró en cuatro fases: (1) generación del corpus documental; (2) diseño del proceso to-be mediante diagramas de arquitectura funcional; (3) procesamiento del corpus con el sistema SAPP y registro sistemático de métricas en planilla de evaluación; y (4) cronometraje de la línea de base del proceso manual, análisis comparativo y redacción de resultados. Las cuatro fases fueron ejecutadas: los resultados de la tercera se reportan en las secciones 5.2 y 5.3, y los de la cuarta en las secciones 5.4 y 5.5. El corpus no está compuesto por documentos comerciales de organizaciones reales. Los veinte documentos fueron generados de forma sintética mediante un script en lenguaje Python, elaborado con asistencia de un modelo de lenguaje conforme a una especificación que fijó diez ítems por documento, rubros comerciales diversos, y nombre y domicilio de cliente ficticios. La generación sintética responde a la imposibilidad de acceder a pedidos comerciales de una organización real, y sus consecuencias sobre el alcance de los resultados se declaran en la sección 5.7. Dado que el corpus no contiene datos personales de personas humanas ni información comercial de terceros, no se requirió la aplicación de los procedimientos de anonimización previstos en la Ley 25.326 de Protección de Datos Personales, ni se transmitieron documentos de terceros a servicios de procesamiento externos.

3.1 Hipótesis de investigación

H1: La implementación del sistema SAPP reduce el tiempo de procesamiento de pedidos en al menos un 50% respecto del proceso manual.

H2: La tasa de error del proceso automatizado es inferior a la del proceso manual, con una reducción de al menos 2 puntos porcentuales.

Ambas hipótesis fijan umbrales cuantitativos cuyo contraste requiere una medición del proceso manual de referencia sobre el mismo conjunto de documentos. Esa medición se ejecutó mediante el cronometraje de una línea de base manual sobre diez documentos del corpus, reportada en la sección 5.4, y el contraste de ambas hipótesis se desarrolla en la sección 5.5. El contraste se apoya en estadística descriptiva sobre una comparación pareada y no en pruebas de inferencia, por las razones que se exponen en la sección 5.7. El trabajo se orienta además por dos preguntas de investigación de carácter funcional, cuya respuesta no depende del contraste de las hipótesis: ¿es viable procesar de forma autónoma pedidos comerciales recibidos en formatos heterogéneos mediante orquestación de flujos y un modelo de lenguaje?, y ¿qué condiciones de entrada determinan el escalamiento de un documento a revisión manual?

3.2 Variables

La Tabla 3 presenta la operacionalización de las variables consideradas en el estudio, con su tipo, definición y métrica asociada.

Tabla 3

Operacionalización de las variables de estudio

Variable	Tipo	Definición	Métrica
Tiempo de Procesamiento	Dependiente	Tiempo total por pedido	Segundos
Tasa de error	Dependiente	Errores por pedido	%
Tipo de proceso	Independiente	Manual vs automatizado	Categórica

Nota. Elaboración propia.

La operacionalización de la variable Tiempo de Procesamiento se realizó mediante el registro automático de timestamps del sistema por los logs de ejecución de n8n: T_inicio corresponde al instante registrado en el log de n8n en que el trigger Gmail detecta el correo entrante, y T_fin al instante en que el nodo Append Row confirma el registro exitoso en Google Sheets. Para el proceso manual, el registro de tiempos se realizó mediante cronometraje directo sobre diez documentos del mismo corpus, procesados por un integrante del equipo siguiendo el procedimiento estándar de lectura, transcripción y registro en planilla. El procedimiento cronometrado y sus resultados se detallan en la sección 5.4.

La variable Tasa de Error se operacionalizó como la proporción de campos discrepantes sobre el total de campos esperados, verificados uno a uno contra el documento de origen. La unidad de análisis es el campo y no el pedido. Se consideró discrepancia toda diferencia entre el valor consignado en el documento y el registrado en la planilla de destino, con el criterio de cómputo que se detalla en la sección 5.1. La misma operacionalización se aplicó al proceso automatizado y al manual, de modo que ambas tasas resulten comparables. No se fijó criterio de significancia estadística, dado que el contraste no emplea pruebas de inferencia.

3.3 Amenazas a la validez

Validez interna: La principal amenaza identificada es la curva de aprendizaje en la configuración del flujo automatizado durante las primeras sesiones de puesta a punto. Para mitigar la curva de aprendizaje del sistema, se realizaron 5 procesamientos de prueba previos al inicio del registro oficial, con ajustes iterativos diarios del prompt y del esquema JSON. Los datos de estas 5 pruebas no forman parte de la muestra analizada. Una segunda amenaza es la posible variación en la calidad de los documentos de entrada: se controló mediante el registro del tipo de entrada (PDF adjunto o texto en el cuerpo del correo) y la inclusión de esta variable

en el registro de cada caso. Validez externa: Al tratarse de una validación funcional en entorno controlado, sobre un corpus construido por el propio equipo y sin implementación en una organización real, la generalización directa de los resultados no es procedente. No obstante, el diseño de la arquitectura es independiente del dominio y replicable en contextos con características similares (volumen documental elevado, heterogeneidad de formatos de origen, recepción de pedidos por correo electrónico). Validez de constructo: la métrica de tiempo admite una medición directa a partir de los registros de ejecución y del cronometraje. La métrica de tasa de error, en cambio, no resultó directamente observable: su cómputo exigió adoptar criterios interpretativos explícitos sobre qué diferencias entre el documento y el registro constituyen error —capitalización, ortografía, número gramatical y unidad de medida—, según se detalla en la sección 5.1. La necesidad de esos criterios constituye en sí misma un hallazgo del trabajo: la exactitud de una extracción documental no es una magnitud unívoca, sino que depende del uso previsto para el dato extraído.

La incorporación de la línea de base del proceso manual añade un componente experimental con participación humana, cuyas amenazas específicas se consignan a continuación. Ninguna de ellas compromete la conclusión sobre H1: la magnitud de la reducción observada, del 83,4 %, resiste con holgura el efecto conjunto de todas ellas, según se cuantifica más adelante.

Operador único, coautor y no ciego respecto de la hipótesis. El cronometraje fue realizado por un solo integrante del equipo de investigación, que conoce el sistema evaluado, la formulación de las hipótesis y el umbral del 50 % que H1 establece. La selección de un operador que no había participado de la ronda automatizada ni de la verificación campo a campo acota el sesgo de familiaridad con los documentos, pero no elimina el conocimiento de

la hipótesis que se pone a prueba. Un diseño más robusto habría requerido un operador externo al equipo y desconocedor del propósito de la medición.

Efecto de práctica dentro de la sesión. Los diez documentos se procesaron de forma consecutiva en una única sesión, en el orden A-10, A-5, A-9, B-3, B-5, B-8, B-9, B-10, A-8 y A-4. Los cuatro primeros casos promedian 137,3 segundos y los seis restantes 115,6, y la correlación entre el orden de ejecución y el tiempo registrado es de −0,41. El signo indica una tendencia a la aceleración a lo largo de la sesión, compatible con una curva de aprendizaje del procedimiento. La tendencia no es sin embargo monótona: el cuarto caso es el más lento de la serie con 158,0 segundos y el quinto el más rápido con 106,0, de modo que el orden no explica por sí solo la dispersión observada. Concurre un segundo factor, documentado en la sección 5.4: la longitud de los nombres de artículo, que es máxima en el documento de cosmética —el cuarto de la serie— y mínima en el de bebidas alcohólicas —el quinto—. El diseño adoptado no permite separar ambos efectos, y esa imposibilidad se declara como limitación. A efectos de acotar su incidencia sobre H1, cabe señalar que el contraste se sostiene aun bajo los supuestos más desfavorables: computando únicamente los seis casos finales, la reducción es del 82,7 %, y tomando el caso manual más rápido de toda la serie como referencia, del 80,8 %.

Representatividad del operador. El transcriptor es un estudiante de ingeniería en informática y no un operador administrativo con experiencia en carga de pedidos comerciales, que es el perfil cuyo trabajo la automatización viene a sustituir. Un operador experimentado podría resultar más rápido, lo que reduciría la magnitud de la mejora, o más lento por procesar volúmenes mayores en condiciones de fatiga, lo que la incrementaría. La dirección del sesgo no puede establecerse con los datos disponibles.

Conocimiento previo del corpus. Los documentos fueron generados mediante un script elaborado por el mismo integrante que realizó el cronometraje, conforme se describe en el

Capítulo 3. Si bien la generación fue automática y el operador no redactó ni revisó el contenido de cada documento antes de transcribirlo, no puede afirmarse que desconociera por completo la estructura del corpus. La circunstancia se consigna por transparencia; su efecto sobre el tiempo de transcripción, si lo hubo, operaría en el sentido de reducirlo y por tanto de subestimar la mejora atribuible al sistema.

Asimetría entre las fronteras de los tiempos comparados. El tiempo del proceso manual se cronometra desde la apertura de la casilla de correo, mientras que el tiempo del proceso automatizado se define como la duración de la ejecución del flujo y excluye por construcción el intervalo de consulta del disparador de correo y el tiempo de entrega del mensaje. La serie manual incorpora, en consecuencia, una etapa de ingesta que la serie automatizada no computa. El intervalo de consulta observado durante la validación se situó en torno a un minuto. La consecuencia debe declararse con precisión: computando ese intervalo, la latencia extremo a extremo del proceso automatizado asciende a unos 80 segundos y la reducción respecto del proceso manual cae al 35,3 %, por debajo del umbral del 50 % que H1 establece. El contraste de H1 reportado en la sección 5.5 se sostiene, en consecuencia, sobre el tiempo de procesamiento y no sobre la latencia extremo a extremo. Corresponde señalar que el intervalo de consulta constituye un parámetro de configuración del nodo disparador y no una propiedad del diseño evaluado: admite reducirse, o sustituirse por un mecanismo de notificación en tiempo real provisto por la interfaz de correo, sin modificar el resto del flujo. Con un intervalo de treinta segundos la reducción extremo a extremo sería del 59,5 % y el umbral de H1 volvería a satisfacerse. La distinción entre ambas magnitudes se consigna aquí porque el trabajo no midió la latencia extremo a extremo de forma sistemática y no puede, por tanto, reportarla como resultado.

Capítulo 4: Desarrollo de la Investigación

El estudio se desarrolló mediante la evaluación del sistema SAPP sobre un corpus de veinte documentos comerciales generados de forma sintética por el equipo de investigación, conforme se describe en el Capítulo 3. El corpus incorpora variabilidad intencional en el rubro comercial, en el léxico de los artículos y en las unidades de medida, así como en el canal de entrada: los documentos se procesaron tanto en formato PDF adjunto, mediante el Pipeline A, como en forma de texto transcrito al cuerpo del correo, mediante el Pipeline B. El cronometraje de la línea de base manual sobre una muestra del mismo corpus se ejecutó conforme al protocolo descrito en la sección 5.1, y sus resultados, junto con la comparación pareada frente al proceso automatizado, se presentan en la sección 5.4.

El corpus generado para esta etapa quedó conformado por los documentos descritos en el Capítulo 5, con variabilidad deliberada en rubro, léxico y unidades de medida, y sirvió de insumo tanto para la validación funcional del sistema como para el cronometraje de la línea de base del proceso manual, ejecutado sobre diez de esos mismos documentos conforme se reporta en la sección 5.4.

En respuesta a este diagnóstico, se diseñó e implementó un flujo de automatización inteligente sobre la plataforma de orquestación n8n (n8n GmbH, 2024) en modalidad autoalojada, capaz de procesar en forma autónoma tanto pedidos recibidos como adjuntos PDF como pedidos incluidos en el cuerpo de texto del correo electrónico. El sistema opera sin intervención humana sobre los pedidos que superan los controles de validación estructurada, derivando a revisión manual únicamente aquellos que no los superan. La implementación fue sometida a una ronda de validación funcional preliminar en entorno controlado durante el mes

de mayo de 2026, orientada a verificar el funcionamiento extremo a extremo del flujo y a identificar condiciones de fallo.

4.1 Arquitectura general

La arquitectura del sistema SAPP se implementó sobre n8n (n8n GmbH, 2024) en modalidad autoalojada mediante contenedor Docker, como orquestador central de flujos, organizándose en cuatro capas funcionales con separación clara de responsabilidades: ingesta, procesamiento inteligente, persistencia y salida.

La capa de ingesta opera mediante un Gmail Trigger configurado sobre una casilla dedicada, que consulta periódicamente la llegada de nuevos correos electrónicos con pedidos. Inmediatamente después del trigger, un nodo de decisión IF clasifica cada mensaje entrante según la presencia o ausencia de archivos adjuntos, bifurcando el procesamiento en dos pipelines independientes y complementarios: el Pipeline A para pedidos recibidos como documentos PDF adjuntos, y el Pipeline B para pedidos incluidos directamente en el cuerpo de texto del correo.

La capa de procesamiento inteligente es compartida por ambos pipelines y constituye el núcleo cognitivo del sistema. En ella, un nodo Basic LLM Chain invoca el modelo Mistral Cloud Chat mediante su API oficial (Mistral AI, 2024), con un prompt de sistema que define las entidades objetivo a extraer y el esquema JSON de salida esperado. Un nodo Structured Output Parser valida que la respuesta del modelo se ajuste al esquema definido. La normalización final de tipos de datos se realiza en nodos Code in JavaScript, que estandarizan formatos numéricos, fechas y códigos de ítem.

La selección de n8n como plataforma de orquestación se fundamentó en tres criterios: su modalidad autoalojada, que mantiene bajo control propio los datos procesados; su integración nativa con la API de Mistral AI y con el ecosistema Google Workspace; y su licenciamiento de código abierto, que permite ejecutar el flujo sin costo por volumen de operaciones. La elección de Mistral Cloud Chat como modelo de lenguaje respondió a su disponibilidad mediante API, a su desempeño con instrucciones en español y a su esquema de costos. No se realizó una evaluación comparativa sistemática frente a otras plataformas ni frente a otros modelos, de modo que estas decisiones se consignan como criterios de selección y no como resultados del trabajo.

La capa de persistencia registra los pedidos procesados en Google Sheets mediante nodos Append Row, con búsqueda previa en Google Drive para verificar la no duplicación del documento. Los archivos PDF originales son almacenados en Google Drive como respaldo documental trazable.

La capa de salida envía automáticamente un correo de confirmación al remitente mediante un nodo Send Message, una vez completada la persistencia del registro. Esta capa se encontraba activa durante la ronda de validación y su funcionamiento quedó documentado: el Capítulo 5 reporta el envío de la confirmación en los casos CP-17, CP-18 y CP-28, y la Captura C.2 del Anexo C exhibe un mensaje efectivamente recibido por el destinatario. La evidencia documentada de cada caso abarca, en consecuencia, desde la recepción del correo hasta el despacho de la confirmación al remitente. El registro estructurado. El circuito incorpora además un nodo que retira la etiqueta de no leído del mensaje procesado, a fin de evitar su reprocesamiento en ciclos posteriores del trigger.

4.2 Pipeline de IA

El pipeline de procesamiento inteligente fue implementado mediante el modelo de lenguaje Mistral Cloud Chat, accedido a través de la integración nativa de n8n con la API de Mistral AI (Mistral AI, 2024). El enfoque adoptado es el de prompt engineering estructurado, en el cual el prompt del sistema instruye al modelo para actuar como extractor de entidades comerciales y especifica el esquema JSON exacto que debe devolver. El sistema define un esquema de salida propio para cada pipeline. El correspondiente al Pipeline A comprende un objeto de cabecera con los campos número de pedido, fecha y cliente, y un arreglo de líneas de ítem con los campos artículo, cantidad y unidad. El correspondiente al Pipeline B comprende únicamente un arreglo de líneas con los campos producto y cantidad. La extracción de identificación fiscal del cliente, precio unitario, monto total, condiciones de pago y fecha de entrega solicitada no forma parte del alcance de la versión evaluada y se identifica como línea de extensión futura. Ambos esquemas se transcriben en el Anexo B.

El flujo diferencia el tratamiento según el tipo de entrada. Para el **Pipeline A** (adjuntos PDF), el nodo Extract From File opera como etapa previa: extrae el contenido textual del documento PDF antes de enviarlo al LLM Chain, eliminando la dependencia de un servicio OCR externo para documentos con texto embebido. Para el **Pipeline B** (texto de email), el contenido del cuerpo del mensaje es enviado directamente al LLM Chain sin preprocesamiento, aprovechando la capacidad del modelo para interpretar texto no estructurado en lenguaje natural.

En ambos casos, el nodo Structured Output Parser de n8n valida la conformidad de la respuesta del modelo con el esquema JSON definido. Las respuestas que no superan esta validación son marcadas como excepciones y derivadas a revisión manual. Los nodos Code in

JavaScript realizan la normalización final: conversión de cadenas a valores numéricos, estandarización de formatos de fecha al estándar ISO 8601 y limpieza de caracteres especiales en códigos de ítem. El resultado es un objeto JSON estructurado y validado, listo para ser persistido en Google Sheets mediante el nodo Append Row correspondiente. Corresponde señalar una característica del diseño con consecuencias sobre el dato finalmente almacenado: la etapa de normalización del Pipeline A proyecta hacia la capa de persistencia únicamente el arreglo de líneas de ítem, de modo que los campos de cabecera —número de pedido, fecha y cliente— son extraídos por el modelo y validados por el parser, pero no se registran en la planilla de destino. La identificación del pedido en la capa de persistencia queda así delegada al nombre del archivo de planilla, que se construye a partir de la dirección del remitente. Esta decisión limita la trazabilidad del registro individual y se identifica como punto de mejora prioritario.

El diseño previó que los pedidos que no superan la validación del esquema JSON fueran derivados a una cola de revisión mediante una notificación al operador administrativo responsable, quien recibiría el documento original y un resumen del error, procedería a la carga manual siguiendo el mismo esquema de campos y registraría la excepción en un log de incidencias. Corresponde señalar que este circuito no llegó a implementarse en la versión evaluada: el flujo exportado no contiene nodos de notificación a un operador ni de registro de incidencias, y la validación reportada en el Capítulo 5 verificó que ningún caso fue derivado a revisión humana por el propio sistema. Cuando la extracción no produce ítems, el flujo prosigue hasta su finalización sin señalar la condición. La descripción precedente corresponde, por tanto, al circuito proyectado, y su implementación se especifica entre las correcciones del Capítulo 7. Durante la ronda de validación preliminar este flujo de excepción se activó en un caso, asociado a un documento PDF que no fue recibido por el flujo como archivo binario adjunto. El nodo Extract From File requiere que el trigger entregue el documento como

propiedad binaria; cuando el PDF no llega en esa forma, la etapa de extracción falla antes de invocar al modelo. Cabe señalar que el documento involucrado contenía texto embebido y era legible, por lo que la causa del fallo no fue la calidad del documento sino la forma de recepción del archivo.

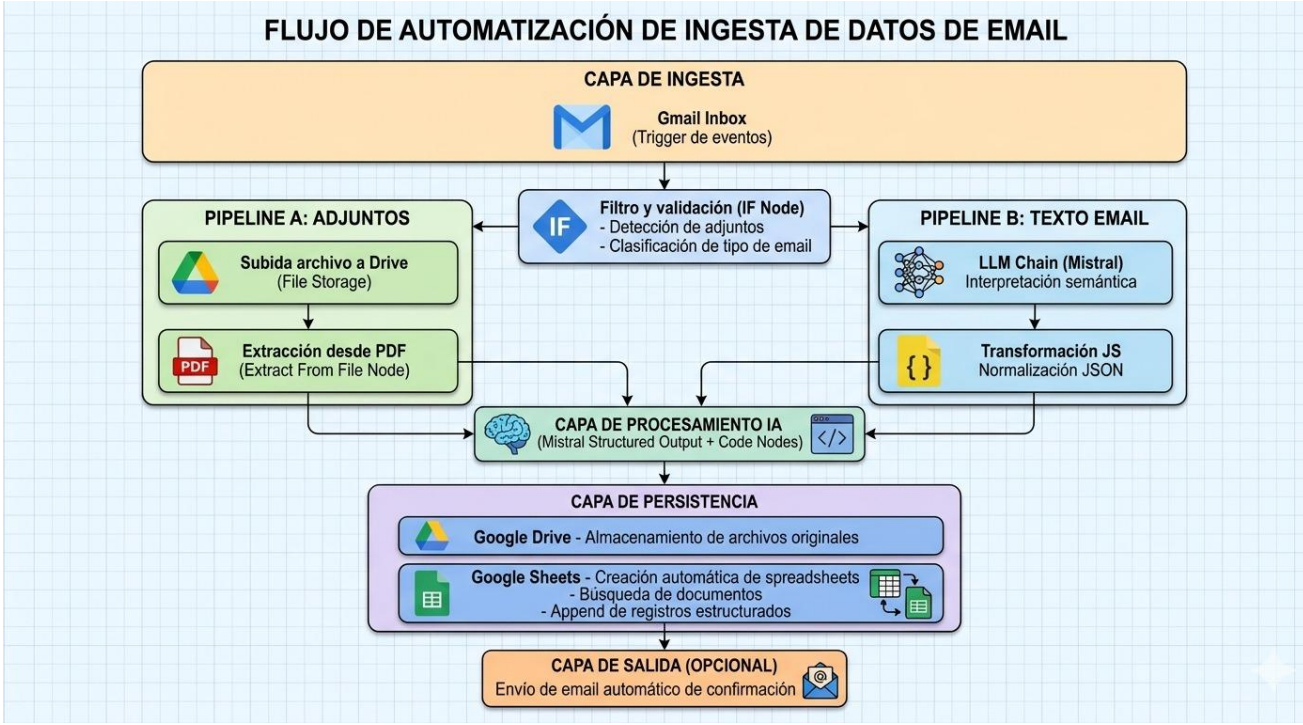
La evaluación de la extracción se realizó mediante verificación manual campo a campo, contrastando cada campo persistido contra el documento original y registrando la proporción de campos correctos sobre campos totales. Los resultados de la validación se presentan en el Capítulo 5.

Cada pipeline emplea un prompt de sistema propio. El del Pipeline A define al modelo como extractor de pedidos a partir de texto de documentos PDF e instruye a devolver exclusivamente el objeto JSON conforme al esquema del parser, sin explicaciones ni delimitadores de bloque de código. El del Pipeline B define al modelo como extractor de datos especializado en logística e incorpora instrucciones de normalización: conversión de cantidades expresadas en palabras a su valor numérico y depuración de los nombres de artículo para conservar únicamente la denominación del producto. Incluye asimismo una instrucción de manejo de casos negativos para correos que no constituyen un pedido. Ambos prompts se transcriben íntegramente en el Anexo A.

4.3 Diagramas

Figura **1**

Arquitectura general del sistema SAPP organizada en cuatro capas funcionales: ingesta, procesamiento inteligente, persistencia y salida.

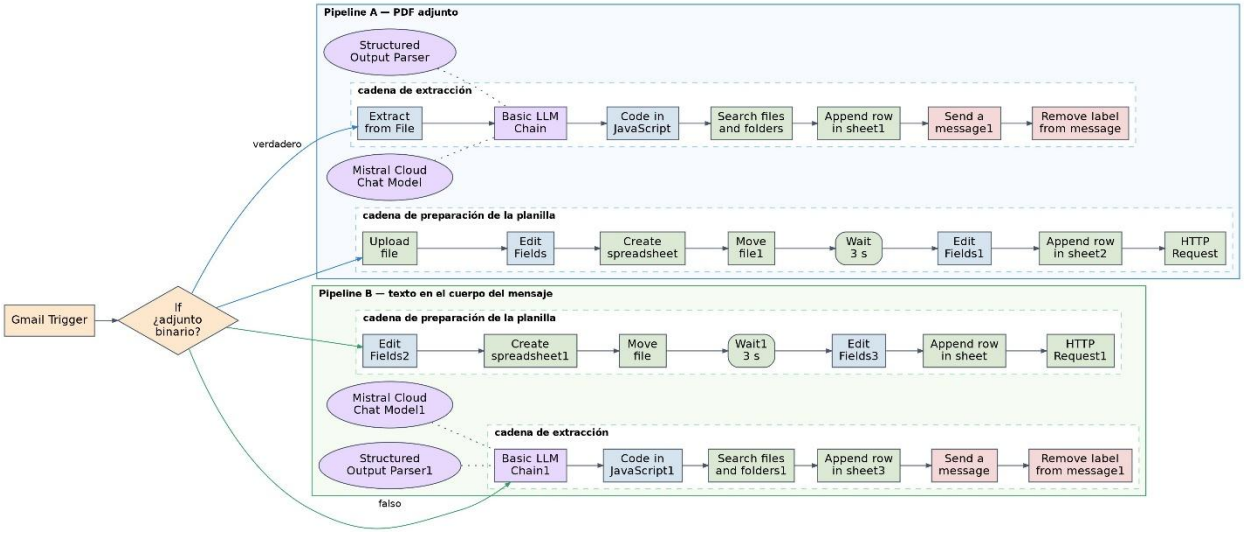


Nota. Elaboración propia.

Figura **2**

Implementación del flujo de automatización en la plataforma n8n autoalojada, con la bifurcación entre el Pipeline A, para adjuntos en formato PDF, y el Pipeline B, para pedidos

redactados en el cuerpo del mensaje. Cada pipeline ejecuta dos cadenas en paralelo: una de extracción y otra de preparación de la planilla de destino.

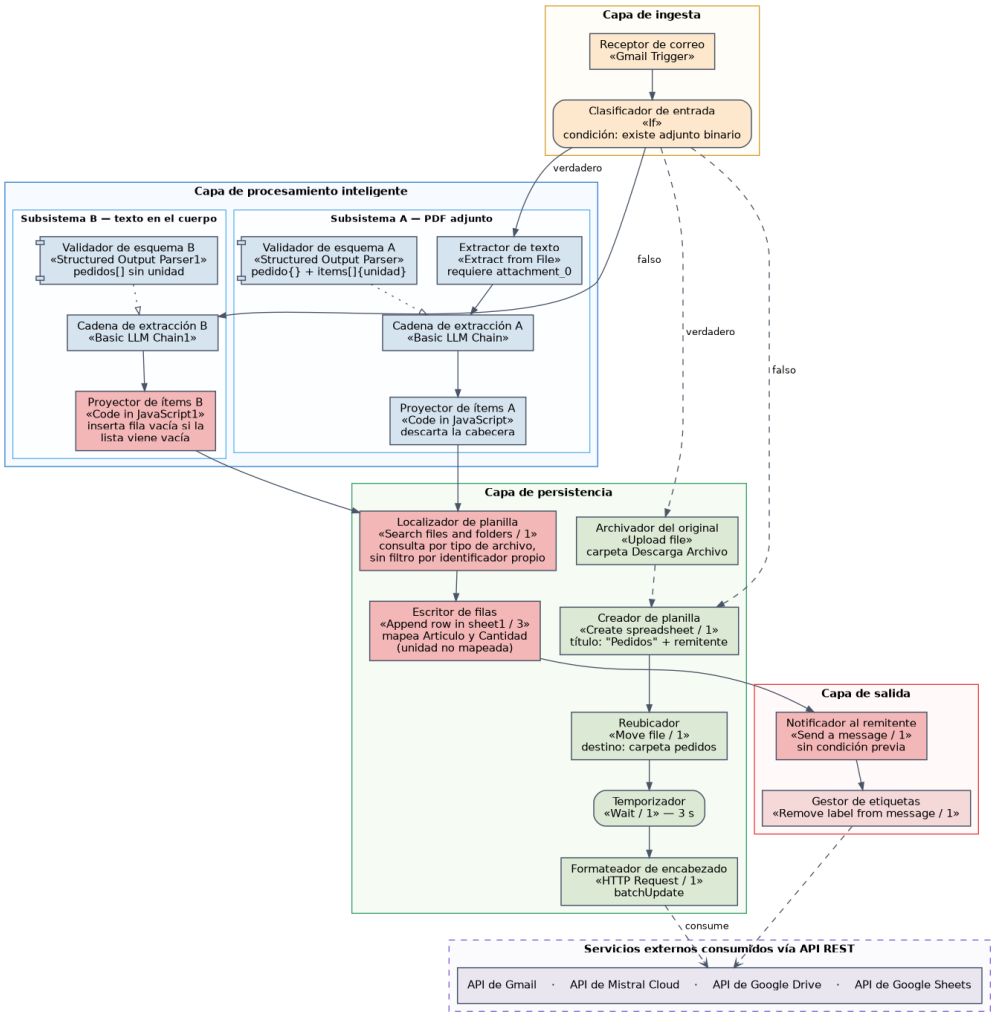


Nota. Elaboración propia a partir del archivo de exportación del flujo; los nombres de los nodos se reproducen tal como figuran en la plataforma. La captura del lienzo original se conserva en el repositorio del trabajo.

El flujo implementado sigue la secuencia: Gmail Trigger → clasificación IF → [Pipeline A: Upload File / Extract From File] o [Pipeline B: LLM Chain directo] → Basic LLM Chain con Mistral → Structured Output Parser → Code in JavaScript → búsqueda en Google Drive → Append Row en Google Sheets → (opcional) Send Message de confirmación.

Figura **3**

Diagrama de componentes del sistema SAPP



Nota. Elaboración propia a partir del archivo de exportación del flujo. En rojo, los componentes en los que la validación ampliada localizó defectos, descritos en la sección 5.3.

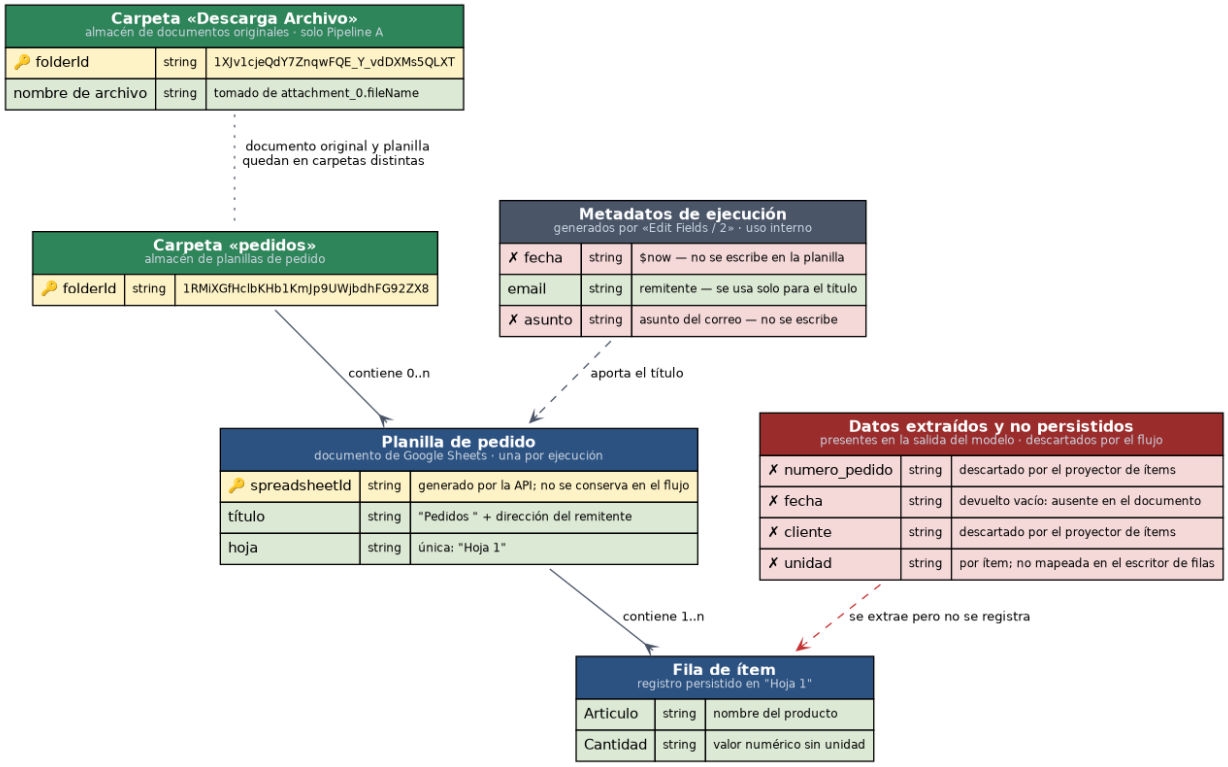
La Figura 3 presenta la descomposición del sistema en componentes y sus dependencias. Se organizan en cuatro capas. La capa de ingesta recibe el mensaje y determina, mediante la evaluación de la existencia de una propiedad binaria adjunta, cuál de los dos subsistemas de procesamiento debe atender el pedido. La capa de procesamiento inteligente agrupa los dos subsistemas, cada uno con su cadena de extracción, su validador de esquema y

su proyector de ítems; ambos consumen el mismo servicio de inferencia mediante interfaz de tipo modelo de lenguaje. La capa de persistencia comprende los componentes de creación, reubicación, localización y escritura de la planilla, además del formateador de encabezado y del archivador del documento original. La capa de salida notifica al remitente y gestiona las etiquetas del mensaje procesado.

Corresponde señalar dos características del diseño que el diagrama vuelve visibles. La primera es que cada subsistema de procesamiento ejecuta dos cadenas en paralelo y no una sola: una cadena construye la planilla de destino y otra extrae e inserta los ítems, y ambas convergen únicamente a través del localizador de planilla. La segunda es que el notificador al remitente no evalúa condición previa alguna: su ejecución está determinada por la finalización del escritor de filas, con independencia del contenido efectivamente persistido. Ambas características son el origen de dos de los defectos documentados en la sección 5.3.

Figura **4**

Modelo de datos de la capa de persistencia



Nota. Elaboración propia. En verde, los campos efectivamente persistidos; en rojo, los campos que el modelo extrae o que el flujo genera y que no llegan al registro final.

La Figura 4 describe la estructura de datos que el sistema materializa sobre Google Sheets y Google Drive. El modelo es deliberadamente descriptivo del estado actual y no normativo: consigna tanto lo que se persiste como lo que se extrae y se descarta, dado que la diferencia entre ambos conjuntos constituye uno de los resultados de la validación.

El almacenamiento se distribuye en dos carpetas de Drive con propósitos distintos. La carpeta Descarga Archivo aloja el documento PDF original y solo interviene en el Pipeline A. La carpeta pedidos aloja las planillas generadas. El documento original y la planilla derivada

de él quedan, por tanto, en ubicaciones separadas y sin referencia mutua: no existe en el modelo ningún campo que vincule una planilla con el archivo del cual proviene.

Cada ejecución genera una planilla independiente, con una hoja única, cuyo título se compone de la palabra Pedidos y la dirección del remitente. La planilla contiene una o más filas de ítem, con dos columnas: nombre de artículo y cantidad. El identificador de la planilla lo asigna la interfaz de Google Sheets en el momento de la creación, pero el flujo no lo conserva para las etapas posteriores, circunstancia que obliga al localizador de planilla a recuperarlo mediante una consulta y que origina el defecto descrito en la sección 5.3.

El modelo carece de identificador de pedido. Ni el número de pedido, ni la fecha, ni el cliente se registran, pese a que el esquema de salida los declara y el modelo los extrae correctamente. La identificación del pedido queda delegada en el título de la planilla, que se construye únicamente a partir del remitente y resulta, en consecuencia, idéntico para todos los pedidos de un mismo cliente. Tampoco se registra la unidad de medida de cada ítem. La cantidad se persiste como valor numérico sin unidad, lo que la vuelve ambigua en los casos en que la unidad de venta no coincide con la unidad individual. La incorporación de estos campos al modelo constituye la corrección especificada en el Capítulo 7.

Capítulo 5: Resultados y Análisis

El presente capítulo reporta los resultados de la validación funcional del sistema SAPP. Se distinguen dos rondas: una ronda preliminar, ejecutada en mayo de 2026, cuyo registro detallado se perdió y de la que solo se conservó un caso documentado, consignado en el Anexo D; y la ronda de validación ampliada, ejecutada el 17 de agosto de 2026 conforme al protocolo descrito en la sección 5.1, que constituye la base evidencial del trabajo. La contrastación con la literatura se desarrolla en el Capítulo 6.

La pérdida del registro de la ronda preliminar constituye una limitación reconocida del presente trabajo y es la circunstancia que motivó el rediseño del protocolo de registro. Los resultados de esa ronda no se extrapolan ni se agregan a los de la validación ampliada: se consignan por separado y el caso de excepción allí documentado se detalla en el Anexo D.

5.1 Protocolo y corpus de la validación ampliada

El corpus está conformado por veinte documentos comerciales de estructura homogénea, elaborados por el equipo de investigación, cada uno con diez ítems, encabezado con número de pedido, rubro y cliente, y una lista numerada de artículos con cantidad y unidad. Cada documento se identifica mediante una nomenclatura de la forma A-n o B-n, donde la letra indica el lote de generación y el número el orden dentro de ese lote; esa denominación designa al documento y no al caso de prueba. Los casos de prueba se identifican mediante la nomenclatura CP-nn, y un mismo documento puede intervenir en más de un caso, como ocurre con Pedidos A-7.pdf, empleado en CP-01 y en su repetición CP-23. La correspondencia entre ambas nomenclaturas consta en la hoja de corpus del protocolo de validación y, para los documentos de la línea de base, en la Tabla 6. Los rubros cubren categorías heterogéneas — alimentos secos, bebidas, limpieza, higiene personal, lácteos, frutas y verduras, congelados,

golosinas, cuidado del hogar, panadería, carnes, librería, cosmética, ferretería, bebidas alcohólicas, snacks, mascotas, bazar, frutos secos y jardinería— con el propósito de introducir variabilidad léxica y de unidades de medida.

Los valores esperados de cada documento se definieron y registraron con anterioridad a su procesamiento, condición que evita que la evaluación resulte circular. La verificación se realizó campo a campo contra el documento de origen. Se adoptó el siguiente criterio de cómputo, fijado con anterioridad al procesamiento y aplicado de forma uniforme a todos los casos. Se consideran incorrectos los campos cuyo valor difiere del consignado en el documento de origen, comprendiendo las diferencias de cantidad, las alteraciones léxicas del nombre del artículo, las alteraciones de su número gramatical y las omisiones o desplazamientos de tilde. Se consideran correctos únicamente los campos que difieren en la capitalización inicial, por tratarse de una variación tipográfica que no altera la identidad del producto ni su ortografía. La sección 5.5 reporta, además del cómputo así definido, el resultado que se obtendría bajo un criterio alternativo que excluyera también las tildes, con el fin de exponer la sensibilidad de la conclusión al criterio adoptado.

Se ejecutaron treinta y dos casos computados: catorce por el Pipeline A, mediante el envío del documento PDF como adjunto binario, y dieciocho por el Pipeline B, mediante la transcripción del texto del pedido al cuerpo del mensaje. Los casos no se ejecutaron en una única sesión sino a lo largo de cuatro jornadas: uno el 12 de agosto de 2026, cinco el 14 de agosto, veintiuno el 17 de agosto y los cinco casos de borde el 27 de agosto. Las cuatro jornadas emplearon la misma versión del flujo, sin modificación alguna de su configuración, razón por la cual sus resultados se agregan en un mismo cómputo; la distribución temporal consta en la columna de fecha del registro de ejecuciones. A los treinta y dos casos computados se suman tres ejecuciones que se excluyen del cómputo: una excepción de configuración del entorno,

ajena al diseño del sistema, que se detalla más adelante; una repetición del caso CP-02 sobre el mismo documento, realizada el 19 de agosto de 2026 para observar la variabilidad entre invocaciones; y una replicación en entorno independiente que se reporta en la sección 5.6. Todas las proporciones de este capítulo toman como denominador los treinta y dos casos computados. Cada ejecución quedó identificada por su registro en la plataforma de orquestación, con marca temporal y duración. El corpus completo, el flujo exportado y el registro por caso se encuentran publicados en el repositorio consignado en la nota que precede a los anexos, archivado bajo el identificador https://doi.org/10.5281/zenodo.22148608, de modo que la ronda aquí reportada resulta reproducible por terceros.

Las proporciones de casos requieren además un criterio de agregación, dado que un caso puede presentar defecto sin que ninguno de los campos que el flujo persistió resulte incorrecto. Se computa un caso con defecto cuando presenta discrepancia en al menos un campo verificado, o cuando el sistema exhibió alguno de los comportamientos anómalos documentados en la sección 5.3, aun habiendo persistido de forma correcta los campos que llegó a escribir. Bajo ese criterio, los casos con defecto de la ronda ampliada son nueve: CP-07, CP-08, CP-10, CP-13, CP-17, CP-18, CP-19, CP-28 y CP-31. Los dos primeros no registran discrepancia de campos —CP-07 no persistió fila alguna y CP-08 no emitió acuse pese al registro exitoso— y se computan con defecto en razón de su comportamiento. Los veintitrés casos restantes se computan sin defecto detectado, proporción que la Tabla 4 consigna desagregada por pipeline: once de catorce en el Pipeline A y doce de dieciocho en el Pipeline B.

Se reportan dos métricas de precisión, cuya distinción resultó necesaria a partir de los hallazgos y que no deben confundirse. La precisión de extracción toma como denominador los campos definidos como esperados antes del procesamiento, conforme al esquema de salida

declarado en cada pipeline. La precisión sobre campos persistidos toma como denominador únicamente los campos que el diseño del flujo escribe efectivamente en la planilla. La brecha entre ambas no corresponde a errores de extracción del modelo, sino a un defecto de la capa de persistencia que se documenta en la sección 5.3.

5.2 Resultados

Tabla 4

Resultados agregados de la validación ampliada

Indicador	Pipeline A	Pipeline B	Total
Casos ejecutados	14	18	32
Casos sin defecto detectado	11	12	23
Campos esperados	390	266	656
Campos correctos	260	250	510
Precisión extremo a extremo	66,7 %	94,0 %	77,7 %
Campos persistidos esperados	260	266	526
Campos persistidos correctos	260	250	510
Precisión sobre campos persistidos	100,0 %	94,0 %	97,0 %

Nota. Elaboración propia a partir del registro de ejecuciones. Se excluye del cómputo el caso CP-12a, correspondiente a una excepción de configuración del entorno. Composición de los denominadores. El Pipeline A comprende catorce casos. Trece de ellos contienen diez ítems, con tres campos esperados por ítem según el esquema declarado —artículo, cantidad y unidad—, lo que arroja 390 campos esperados; el caso restante, CP-07, corresponde al documento sin capa de texto extraíble y no admite campos esperados, por lo que aporta cero al denominador. Los campos persistidos esperados del Pipeline A son 260, dado que el flujo escribe dos de los tres campos de cada ítem y no la unidad. El Pipeline B comprende dieciocho casos: once de diez ítems con dos campos por ítem, que aportan 220 campos; cuatro de cinco ítems, que aportan 40; y tres casos negativos —correos que no constituyen pedidos o cuyas cantidades no son determinables— con dos campos esperados cada uno y valor esperado nulo, que aportan 6. El total del Pipeline B asciende así a 266 campos esperados. Los campos persistidos esperados del Pipeline B ascienden también a 266: el esquema de ese pipeline declara únicamente los campos de producto y cantidad, ambos persistidos, de modo que el valor resulta deducible del diseño para todo caso, con independencia de que el registro consigne el dato desagregado. Las dos precisiones del Pipeline B coinciden en 94,0 % por construcción y no por coincidencia: el esquema de ese pipeline declara únicamente los campos de producto y cantidad, que son exactamente los que el flujo escribe, de modo que el conjunto de campos esperados

y el de campos persistidos esperados difieren solo en los cuatro casos sin dato desagregado señalados más arriba, sin que ello altere la proporción. La distinción entre ambas métricas resulta significativa únicamente en el Pipeline A, cuyo esquema declara un campo adicional que el flujo no escribe. La precisión extremo a extremo del Pipeline A está determinada por la no persistencia del campo unidad, documentada en la sección 5.3: los 110 campos de diferencia corresponden a valores que el modelo extrae correctamente, conforme acredita la Captura C.5 del Anexo C, y que el nodo de escritura no mapea. No constituyen, por tanto, errores de extracción del modelo.

El sistema no registró excepciones atribuibles a su diseño en ninguno de los treinta y dos casos computados: la totalidad de los documentos fue procesada hasta el final del flujo sin interrupción. Corresponde precisar que ello no equivale a que todos hayan producido un registro: el caso CP-07, correspondiente al documento sin capa de texto extraíble, concluyó sin persistir fila alguna, conforme se detalla en la sección 5.3. Corresponde consignar un dato que el propio capítulo documenta y que conviene no confundir con una medida de desempeño: el sistema no escaló ningún caso a revisión manual. Los dos falsos positivos fueron persistidos y confirmados al remitente, y el error de cantidad del caso CP-28 resultó indetectable para la validación de esquema. La proporción de casos que el flujo derivó a revisión humana fue, en consecuencia, nula, y esa es precisamente la carencia que la sección 5.3 documenta. La proporción de casos procesados sin defecto detectado por la verificación externa realizada por el equipo fue del 71,9 % (23 casos sobre 32 computados). Los cuatro casos restantes corresponden a dos falsos positivos ante correos que no constituían pedidos y a dos casos con errores de extracción, todos ellos descritos en la sección 5.3. El indicador mide, por tanto, la exactitud del resultado verificada a posteriori, y no la capacidad del sistema para discriminar por sí mismo los casos que requieren intervención.

Tabla 5

Tiempos de procesamiento por pipeline

Estadístico	Pipeline A	Pipeline B	Total
Casos	14	17	31
Mínimo (s)	14,5	15,9	14,5
Mediana (s)	22,1	19,2	20,9
Máximo (s)	36,0	25,1	36,0
Media (s)	23,8	19,4	21,4

Nota. Elaboración propia a partir de la duración informada por la plataforma de orquestación. El tiempo de procesamiento se define como la duración de la ejecución desde la activación del flujo hasta la finalización del último nodo; no incluye el intervalo de consulta del disparador ni el tiempo de entrega del correo, conforme a la acotación de la sección 3.3. La serie comprende treinta y uno de los treinta y dos casos computados: el caso CP-17 fue registrado sin consignar la duración de la ejecución, de modo que queda fuera del cálculo de los estadísticos de tiempo aunque integra el cómputo de las restantes métricas.

La distribución de los tiempos no es uniforme dentro del rango observado. En el Pipeline A, ocho de las catorce ejecuciones se concentran entre 20,3 y 22,6 segundos; cinco se apartan por encima, con 24,4, 25,3, 28,3, 35,1 y 36,0 segundos, y una queda por debajo, con los 14,5 segundos de CP-07, cuya brevedad se explica porque el flujo no extrajo ítem alguno del documento. El caso más ilustrativo de esta dispersión es el par CP-01 y CP-23, que procesan el mismo documento por el mismo pipeline y registran 22,6 y 36,0 segundos respectivamente. La variabilidad no es atribuible al pipeline ni al documento: la diferencia entre procesar un mismo contenido por el Pipeline A o por el Pipeline B, medida en el par CP-03 y CP-32, fue de 0,9 segundos, muy inferior a la observada entre repeticiones del mismo caso. Se reporta en consecuencia el rango completo y la mediana, y no únicamente la media, que ningún caso individual representa.

El par CP-03 y CP-32 constituye una comparación controlada entre pipelines. Ambos casos procesan el mismo documento, uno como PDF adjunto y otro como texto en el cuerpo del mensaje. La salida persistida resultó idéntica fila por fila y valor por valor en los dos casos: las mismas dos columnas, los mismos diez artículos y las mismas diez cantidades. El esquema del Pipeline A declara un campo unidad que el esquema del Pipeline B no contempla; esa

asimetría, real en la etapa de extracción, no produce ninguna diferencia observable en el resultado persistido.

5.3 Hallazgos

La validación identificó seis comportamientos relevantes: cinco defectos y uno favorable al diseño. Los cuatro primeros defectos se localizan en un nodo específico del flujo, de modo que la corrección correspondiente puede especificarse sin ambigüedad; el quinto es de carácter transversal y corresponde a la ausencia de un mecanismo antes que a la configuración de un nodo.

Primero, falso positivo ante correos que no constituyen pedidos. Ante una consulta general (CP-17) y ante un saludo sin contenido comercial (CP-18), el sistema creó la planilla, persistió una fila con artículo vacío y cantidad cero, y envió al remitente el mensaje de confirmación de pedido recibido. La causa no se limita a la ausencia del campo es_pedido en el esquema del Structured Output Parser, como se había supuesto a partir de la inspección del prompt. El nodo Code in JavaScript1 contiene una guarda que, cuando la lista de pedidos devuelta por el modelo viene vacía, incorpora una fila con producto vacío y cantidad cero para evitar una salida sin ítems. Esa fila artificial se persiste y habilita la continuación del flujo hasta el nodo de envío, que no evalúa condición previa alguna. El modelo, por su parte, había resuelto correctamente el caso al devolver una lista vacía. La corrección requiere dos cambios: incorporar el campo al esquema y sustituir la guarda por un nodo de corte previo a la persistencia y al envío.

Segundo, el campo unidad se extrae y se descarta. El esquema del Pipeline A define el campo unidad para cada ítem y el nodo Code in JavaScript lo proyecta explícitamente. El nodo Append row in sheet1, sin embargo, mapea únicamente las columnas Articulo y Cantidad, de

modo que el valor se pierde antes de la planilla. La Captura C.5 del Anexo C documenta la salida del nodo Basic LLM Chain con el campo unidad presente para cada ítem, junto con la planilla resultante sin esa columna. El efecto no es de mera completitud: en tres casos del corpus el dato persistido queda ambiguo. En CP-27 el documento consigna treinta docenas de facturas y la planilla registra el valor treinta sin indicar la unidad, de modo que no es posible determinar si corresponden treinta o trescientas sesenta unidades. En CP-16 el documento consigna diez kilogramos de clavos y la planilla registra diez. En CP-05 el documento emplea cinco unidades de venta distintas para diez artículos. La omisión de la unidad vuelve el dato insuficiente para despachar el pedido.

Tercero, la extracción no es determinista. Los dos nodos de modelo del flujo, Mistral Cloud Chat Model y Mistral Cloud Chat Model1, no fijan el parámetro de temperatura, por lo que operan con el valor por defecto del proveedor. En consecuencia, una misma entrada puede producir salidas distintas entre invocaciones. La ronda registró tres manifestaciones de esta variabilidad. La capitalización de los nombres de artículo alternó sin patrón: seis casos del Pipeline B conservaron la mayúscula inicial del documento y cuatro la normalizaron a minúscula. Seis nombres de artículo, sobre cien procesados por el Pipeline B, fueron singularizados sin que el prompt lo solicite; en CP-31 la alteración afectó a cinco de diez artículos, y de forma inconsistente dentro del propio documento, ya que otros dos conservaron el plural. Por último, en CP-28 el modelo tomó la línea completa como nombre de artículo y asignó cantidad uno en los dos primeros ítems, sobre un documento que en pruebas previas se había extraído correctamente. Se observa además que ambos pipelines operan sobre modelos distintos. La inspección de la configuración vigente confirma que el nodo del Pipeline A emplea el modelo mistral-medium y el del Pipeline B el modelo mistral-small, este último por resolución del valor predeterminado del nodo y no por una decisión explícita de diseño, dado que el archivo de exportación no consigna modelo para ese pipeline. La circunstancia

constituye una variable no controlada de la evaluación: las diferencias de comportamiento observadas entre los dos pipelines, entre ellas la relativa al tratamiento de la unidad de medida y la alteración del número gramatical de los nombres, admiten atribuirse tanto a la diferencia de esquema y de prompt como a la del modelo subyacente, sin que el diseño empleado permita discriminar entre ambas causas. La comparación entre pipelines reportada en la sección 5.2, que registró salidas persistidas idénticas sobre un mismo documento, debe leerse con esa salvedad.

El caso de CP-28 merece atención particular porque el error resulta indetectable por validación de esquema: el nombre de artículo es una cadena válida y la cantidad uno es un entero válido, de modo que el Structured Output Parser acepta la salida, la fila se persiste y el remitente recibe la confirmación. El sistema no dispone de ningún mecanismo que señale que la extracción fue incorrecta. Una cantidad de uno en lugar de cuarenta es un error de consecuencias operativas directas que ningún control del flujo actual detendría.

Cuarto, la escritura se dirige a una planilla que el flujo no identifica de forma unívoca. El nodo Search files and folders1 consulta Google Drive solicitando archivos de tipo hoja de cálculo contenidos en la carpeta de destino, con límite de un resultado. La consulta no filtra por nombre de archivo, ni por fecha de creación, ni por el identificador de la planilla que la propia ejecución acaba de crear en el nodo Create spreadsheet1. Dado que el título de todas las planillas se construye como la concatenación de la palabra Pedidos y la dirección del remitente, los archivos generados por un mismo remitente resultan homónimos, y la correspondencia entre la planilla creada y la escrita queda determinada por el orden de resultados que devuelve la interfaz de Drive. El nodo Wait1, que introduce una espera fija de tres segundos, constituye una mitigación temporal y no una garantía de correspondencia. Durante la ronda no se observaron escrituras cruzadas; sí se registró un episodio de esta naturaleza en pruebas previas

al protocolo, con la configuración de carpetas aún sin corregir. El defecto se consigna, por tanto, como latente y acreditado por inspección del flujo exportado, y no como observado durante la validación.

La homonimia de las planillas tuvo además un efecto verificado en el uso. Al término de la ronda, la carpeta de destino contenía más de veinte archivos con título idéntico, indistinguibles entre sí sin abrirlos. Durante la propia validación, el operador accedió en dos ocasiones a la planilla equivocada al intentar verificar un caso. La observación importa porque el defecto se manifestó en condiciones de uso reales y no como inferencia sobre el diseño. Cabe consignar que el sistema crea una planilla nueva por cada pedido procesado, de modo que las filas de pedidos distintos no se mezclan en el curso normal de operación; el problema no es la acumulación de registros sino la imposibilidad de identificar a qué pedido corresponde cada archivo.

Quinto, y en sentido favorable, el modelo no fabrica los campos ausentes. Ningún documento del corpus consigna fecha, campo declarado como requerido en el esquema de salida del Pipeline A. La verificación sobre el registro de ejecución del nodo Basic LLM Chain, documentada en la Captura C.5 del Anexo C, muestra que el modelo devuelve el campo vacío en lugar de generar un valor plausible. El comportamiento es conservador y deseable, y contrasta con uno de los modos de falla más señalados en la literatura sobre extracción de información con modelos de lenguaje. La misma captura permite constatar que los campos de cabecera numero_pedido y cliente se extraen correctamente y se pierden después, dado que el nodo Code in JavaScript proyecta a la planilla únicamente las líneas de ítem.

Sexto, y como resultado transversal de los cinco casos de borde ejecutados, el sistema no informa las condiciones que le impiden completar el procesamiento. La constatación no

corresponde a un nodo en particular sino a la ausencia de un mecanismo, y se manifiesta de dos formas opuestas.

En el caso CP-07 se remitió el pedido como fotografía incorporada a un documento PDF, sin capa de texto extraíble. El sistema creó la planilla de destino y no persistió fila alguna. El resultado es coherente con el alcance declarado en la sección 1.6, dado que el sistema no implementa reconocimiento óptico de caracteres, de modo que la imposibilidad de procesar el documento no constituye un defecto sino una limitación conocida. Sí lo constituye, en cambio, el tratamiento de esa condición: el flujo no deriva el caso a revisión manual, no registra excepción y no notifica al remitente. El pedido se pierde sin que ninguna de las partes lo advierta. En el caso CP-10 ocurre algo equivalente por otra vía: ante un correo con dos documentos adjuntos, el sistema procesó el primero y descartó el segundo, y remitió una única confirmación redactada en singular que el cliente interpretaría como acuse de ambos pedidos. En el caso CP-19, ante un pedido cuyos productos eran identificables pero cuyas cantidades se expresaban mediante cuantificadores imprecisos, el sistema produjo la misma salida que ante un correo sin pedido alguno: una fila vacía y una confirmación. Corresponde señalar que el modelo se comportó correctamente al no fabricar cantidades, y que la información de los tres productos identificados se perdió en la capa de orquestación.

El caso CP-08 invierte el patrón. Un pedido remitido en un mensaje reenviado se procesó y persistió correctamente, pero el flujo no retiró la etiqueta del mensaje ni emitió confirmación al remitente, de modo que quien reenvió el pedido no obtuvo acuse de recibo pese a que el pedido fue efectivamente registrado. La verificación posterior de esta condición reveló un defecto de mayor alcance: al alterarse manualmente el estado de lectura del mensaje, el disparador volvió a tomarlo y el sistema generó un registro duplicado completo del mismo pedido, emitiendo en esta segunda ocasión la confirmación omitida. El flujo delega, por tanto,

el control de idempotencia en el estado de lectura del correo, atributo modificable por cualquier usuario del buzón y ajeno al sistema, y no dispone de mecanismo propio que impida el registro duplicado de un pedido ya procesado. Es el único defecto de los documentados que produce duplicación de datos, y su activación no requiere condiciones excepcionales: basta que un operador marque y desmarque un mensaje como leído.

El caso CP-24, ejecutado con la carpeta de destino previamente vacía, no manifestó la condición de carrera prevista y confirma por vía inversa el diagnóstico del cuarto hallazgo. La consulta que el nodo de localización dirige a la carpeta resulta ambigua únicamente cuando esta contiene más de una planilla; con la carpeta vacía, el único archivo que puede devolver es el que la propia ejecución acaba de crear. El escenario evaluado es, en consecuencia, el más favorable posible para ese defecto, y su resultado satisfactorio no permite inferir que la escritura sea correcta en condiciones de operación normales, en las que la carpeta acumula una planilla por cada pedido procesado.

Considerados en conjunto, los casos CP-07, CP-08, CP-10, CP-17, CP-18, CP-19 y CP-28 describen un mismo comportamiento: el sistema produce un resultado incorrecto, incompleto o duplicado y prosigue su ejecución hasta el final sin señal alguna de anomalía, sea emitiendo una confirmación improcedente o, en el caso del reenvío, omitiendo la que correspondía. La regularidad sugiere que no se trata de siete defectos independientes sino de una única carencia de diseño: el flujo carece de toda correspondencia verificable entre lo que procesa y lo que comunica. Esta lectura fundamenta de manera directa las recomendaciones formuladas en el Capítulo 7 sobre validaciones de plausibilidad y notificación de excepciones, y constituye, a juicio de este trabajo, el resultado de mayor relevancia para el diseño de arquitecturas equivalentes.

El conjunto de los hallazgos admite una lectura unitaria. En los treinta y dos casos computados, el modelo de lenguaje interpretó correctamente la estructura del pedido, resolvió la normalización de cantidades expresadas en palabras, distinguió la unidad de venta de la cantidad, y se abstuvo de completar campos ausentes. Los defectos que comprometen el resultado se localizan en la capa de orquestación y persistencia: un campo que no se mapea, una guarda que fabrica una fila, una búsqueda que no identifica su destino y un parámetro de configuración sin fijar. Esta distribución es relevante para el diseño de sistemas equivalentes, en la medida en que sugiere que el riesgo de este tipo de arquitecturas no reside principalmente en la capacidad del modelo sino en la ingeniería que lo rodea.

5.4 Línea de base del proceso manual

El protocolo previsto en la sección 5.1 contemplaba el cronometraje de una línea de base del proceso manual sobre los mismos documentos procesados por el sistema. Esta medición se ejecutó el 21 de agosto de 2026 sobre diez documentos del corpus, y constituye el grupo de comparación que permite contrastar las hipótesis enunciadas en el Capítulo 3.

La medición fue realizada por Juan Darío Sinatra, integrante del equipo de investigación que no participó de la ronda de ejecución automatizada ni de la verificación campo a campo. El operador no había examinado el contenido de los documentos con anterioridad al cronometraje, si bien elaboró el script que los generó, circunstancia que se consigna entre las amenazas a la validez de la sección 3.3. La elección del operador responde a un criterio metodológico explícito: quien ejecutó la ronda automatizada había manipulado los documentos en reiteradas ocasiones, de modo que su tiempo de transcripción habría reflejado el reconocimiento de un material conocido antes que el procesamiento de un pedido nuevo, y habría subestimado la duración real de la tarea.

El procedimiento cronometrado reproduce el que ejecuta el sistema: abrir la casilla de correo, abrir el documento, leer los ítems, transcribir el artículo y la cantidad a una planilla de cálculo nueva, y guardar. El cronómetro corre desde la apertura de la casilla hasta el guardado de la última fila, y no computa el cierre de las ventanas ni la descarga del archivo, por no formar parte de la secuencia que ejecuta el flujo automatizado. La transcripción se realizó mediante tipeo, sin recurrir al copiado y pegado del texto del documento, dado que esta última operación mediría el uso del portapapeles y no el trabajo administrativo que la automatización viene a sustituir. Cada documento se procesó de forma individual y sin interrupciones. Los tiempos se registraron con cronómetro, consignando el instante de inicio y el de finalización con precisión de segundos. Uno de los casos se documentó además mediante grabación de pantalla, a modo de registro del procedimiento empleado; esa grabación se encuentra disponible en el repositorio del trabajo.

Los diez documentos cronometrados cuentan con su contraparte procesada por el sistema durante la ronda del 17 de agosto, de modo que la comparación se establece por pares sobre documentos idénticos y no entre dos conjuntos distintos. Esta condición elimina la variabilidad atribuible a la composición de la muestra y permite atribuir la diferencia observada al método de procesamiento.

Tabla 6

Comparación pareada entre el proceso manual y el proceso automatizado

Doc.	**Caso**	**Rubro**	**Manual**	**Sistema**	**Redc.**
A-9	CP-26	Cuidado del hogar	142,5	20,9	85,4 %
A-10	CP-27	Panadería	130,0	21,0	83,9 %
B-3	CP-15	Cosmética	158,0	21,8	86,2 %
B-5	CP-20	Bebidas alcohólicas	106,0	18,5	82,5 %

Doc.	Caso	Rubro	Manual	Sistema	Redc.
B-8	CP-29	Bazar	112,8	21,3	81,1 %
B-9	CP-30	Frutos secos	125,0	19,1	84,8 %
B-10	CP-31	Jardinería	123,0	19,2	84,4 %
A-8	CP-21	Golosinas	107,0	20,3	81,1 %
A-4	CP-05	Higiene personal	120,0	21,7	82,0 %
A-5	CP-06	Lácteos	118,8	20,4	82,8 %
Media	—	—	124,3	20,4	83,4 %
Mediana	—	—	121,5	20,6	83,4 %
Desvío est.	—	—	16,1	1,1	—

Nota. Elaboración propia. Tiempos expresados en segundos. Cada fila compara el tiempo de transcripción manual de un documento con el tiempo de procesamiento registrado por el sistema sobre ese mismo documento. Todos los documentos contienen diez ítems. Las columnas de tiempo se presentan redondeadas a un decimal, mientras que la reducción de cada fila se calculó sobre los valores sin redondear del registro de ejecuciones, por lo que su recálculo a partir de los valores exhibidos puede arrojar diferencias en la primera cifra decimal. El valor de 83,4 % consignado en la fila de medias corresponde al promedio de las reducciones individuales; la reducción calculada sobre las medias de ambas columnas arroja 83,6 %.

El tiempo medio del proceso manual fue de 124,3 segundos, con una mediana de 121,5 segundos y un rango comprendido entre 106,0 y 158,0 segundos. El tiempo medio del proceso automatizado sobre los mismos diez documentos fue de 20,4 segundos. La diferencia media es de 103,9 segundos por documento, equivalente a un factor de aceleración de 6,1.

La reducción observada se distribuye entre el 81,1 % y el 86,2 %, con una media del 83,4 %. Corresponde señalar que la magnitud de la reducción es notablemente homogénea: los diez pares se concentran en una franja de cinco puntos porcentuales, sin que ningún documento se aparte del comportamiento general. Esta homogeneidad refuerza la interpretación del resultado, dado que la ventaja del sistema no depende del rubro ni de la extensión de los nombres de artículo.

Un resultado adicional, no previsto en el diseño, se desprende de la dispersión de ambas series. El coeficiente de variación del proceso manual es del 12,9 %, frente al 5,6 % del proceso automatizado sobre el mismo conjunto de documentos. El sistema resulta, por tanto, no solo más rápido sino también más predecible en su duración. Esta observación matiza la variabilidad de tiempos documentada en la sección 5.2 sobre el conjunto de treinta y un casos con tiempo registrado: los valores extremos allí registrados corresponden a corridas aisladas y no caracterizan el comportamiento habitual del flujo, que en estos diez documentos se mantuvo entre 18,5 y 21,8 segundos.

El tiempo de transcripción manual guarda relación con la longitud de los nombres de artículo y no únicamente con la cantidad de ítems, que es constante en todo el corpus. Los documentos de menor duración —bebidas alcohólicas, con 106,0 segundos, y golosinas, con 107,0— presentan nombres breves, en su mayoría de una sola palabra. El de mayor duración —cosmética, con 158,0 segundos— presenta denominaciones extensas de tres y cuatro palabras. El proceso automatizado no muestra esta dependencia.

5.5 Contraste de las hipótesis

Las hipótesis H1 y H2, enunciadas en el Capítulo 3, se contrastan a continuación con los datos de la comparación pareada. Se emplea estadística descriptiva y no pruebas de inferencia: el objetivo del contraste es determinar si el umbral declarado en cada hipótesis se alcanza sobre el conjunto de documentos evaluados, y no estimar parámetros poblacionales a partir de una muestra, para lo cual el tamaño y el procedimiento de selección del corpus no ofrecen sustento.

La hipótesis H1 sostiene que el sistema reduce el tiempo de procesamiento en al menos un 50 % respecto del proceso manual. La reducción media observada es del 83,4 %, y la

reducción mínima registrada en un documento individual es del 81,1 %. Los diez pares evaluados superan el umbral enunciado, sin excepciones. H1 se sostiene sobre el corpus evaluado. Corresponde acotar el alcance de esta afirmación: el resultado vale para documentos de estructura homogénea, de diez ítems, y para un único operador humano de referencia; su generalización a otros formatos documentales, a pedidos de extensión variable o a operadores con distinto grado de destreza requiere una evaluación específica.

La hipótesis H2 sostiene que el sistema reduce la tasa de error en al menos dos puntos porcentuales respecto del proceso manual. El contraste de esta hipótesis exige una precisión previa sobre qué se computa como error, dado que la validación reveló que ambos procesos yerran, pero no del mismo modo.

Tabla 7

Errores registrados por tipo, según proceso

Tipo de discrepancia	Manual (100 art.)	Sistema (100 art.)
Cantidad incorrecta	0	2
Nombre alterado (léxico)	5	6
Alteración de la identidad del producto	1	0
Tilde omitida o mal colocada	6	0
Capitalización alterada	52	40
Total de discrepancias (criterio adoptado)	12	8
Total excluyendo tildes (sensibilidad)	6	8

Nota. Elaboración propia. La columna del proceso manual comprende los cien artículos de los diez documentos cronometrados en la línea de base. La columna del sistema comprende los cien artículos de los diez casos del Pipeline B que procesan documentos de diez ítems. Ambos conjuntos no recaen sobre los mismos diez documentos: seis documentos son comunes a ambas columnas y cuatro difieren, dado que la selección de la línea de base privilegió los documentos menos manipulados durante la ronda automatizada, mientras que la del Pipeline B queda determinada por el canal de ingreso empleado. El contraste de H2 compara, en consecuencia, dos tasas de error obtenidas sobre corpus parcialmente superpuestos y de composición equivalente en extensión y estructura, pero no idénticos; el alcance de la conclusión debe entenderse acotado por esa circunstancia. El total de discrepancias comprende los errores de cantidad, las alteraciones léxicas del nombre, las alteraciones de la

identidad del producto y las tildes omitidas o mal colocadas, conforme al criterio de cómputo declarado en la sección 5.1. Se excluye únicamente la capitalización. Se consigna en fila aparte el total que se obtendría excluyendo también las tildes, a efectos del análisis de sensibilidad de la sección 5.5.

Bajo el criterio de cómputo declarado en la sección 5.1, el proceso manual registra doce discrepancias sobre cien artículos y el proceso automatizado ocho sobre cien. La diferencia es de cuatro puntos porcentuales en favor del sistema, de modo que H2 se sostiene sobre el corpus evaluado, que exigía una reducción de al menos dos puntos. La conclusión es sensible al tratamiento de las tildes, y corresponde exponerlo. Si las omisiones y los desplazamientos de tilde se excluyeran del cómputo, por entenderse que no alteran la identidad del artículo designado, el proceso manual registraría seis discrepancias y el automatizado ocho, y H2 no se sostendría. Ambos cómputos se reportan en la Tabla 7. Se adopta el primero por una razón de procedimiento y no de resultado: es el criterio declarado con anterioridad a la medición, y un criterio de cómputo fijado después de conocer los datos no puede sustentar la aceptación ni el rechazo de una hipótesis. Corresponde señalar que la totalidad de las seis discrepancias que separan un cómputo del otro pertenece al proceso manual, de modo que la elección del criterio declarado favorece la conclusión del trabajo; se adopta, no obstante, porque era el declarado, y la alternativa se reporta para que el lector pueda evaluar la robustez del resultado por sí mismo.

El resultado exige, sin embargo, una lectura cualitativa que la comparación agregada oscurece, porque los errores de uno y otro proceso difieren en naturaleza y en consecuencia operativa. El operador humano no cometió ningún error de cantidad en los cien artículos transcritos: la totalidad de los valores numéricos es correcta. Sus discrepancias se concentran en la ortografía —seis tildes omitidas o mal colocadas, incluida una desplazada a la sílaba incorrecta en el término «Jábon»— y en la construcción del nombre, con dos casos en que incorporó una preposición ausente en el original y dos en que alteró el número gramatical. El sistema, en cambio, no omitió ni desplazó una sola tilde en los treinta y dos casos computados,

pero registró dos errores de cantidad en el caso CP-28, donde asignó el valor uno a dos artículos cuyas cantidades reales eran cuarenta y veinticinco.

La distinción es relevante desde el punto de vista operativo. Un nombre de artículo con una tilde omitida sigue identificando el producto solicitado para un operario de depósito, aunque impida el cotejo literal contra un catálogo. Una cantidad de uno en lugar de cuarenta produce un despacho incorrecto. En este sentido, la afirmación de que el proceso manual registra menos errores requiere la salvedad de que sus errores son de menor severidad, y la afirmación inversa —que el sistema es más exacto— tampoco se sostiene sin calificar.

Se registró además una única discrepancia que altera la identidad del producto, y corresponde al proceso manual: en el documento de frutos secos el operador transcribió «Mix de frutos rojos secos» donde el documento consigna «Mix de frutos secos», incorporando un término ausente que designa una mercadería distinta. El sistema no incurrió en ninguna alteración de esta clase.

La comparación por documento revela, por último, que ninguno de los dos procesos domina de forma uniforme. En el documento de jardinería el sistema registró su mayor tasa de error, con cinco de diez nombres singularizados, mientras el operador humano conservó el número gramatical de los diez. En el documento de frutos secos ocurrió lo contrario: el sistema transcribió los diez artículos de forma literal y el operador introdujo el término espurio antes mencionado. Los dos procesos fallan sobre documentos distintos y por mecanismos distintos, lo que sugiere que su combinación —revisión humana sobre salida automatizada— produciría una tasa de error inferior a la de cualquiera de ellos por separado.

Una observación registrada durante el cronometraje documenta un mecanismo que el flujo automatizado no posee. En el documento de golosinas el operador escribió inicialmente

«Barras de cereal», advirtió la discrepancia durante la propia transcripción y la corrigió a «Barra de cereal», todo ello dentro del tiempo cronometrado. El proceso manual incorpora, por tanto, una verificación concurrente que consume parte de su duración; el sistema no dispone de control alguno sobre el contenido extraído, y en el caso CP-28 persistió una cantidad errónea y emitió la confirmación al remitente sin que ninguna etapa del flujo señalara la anomalía. Parte de la diferencia de tiempo observada en la sección 5.4 corresponde, en consecuencia, a actividad de verificación que el proceso automatizado omite. Esta constatación fundamenta de manera directa la recomendación de incorporar validaciones de plausibilidad sobre los datos extraídos, formulada en el Capítulo 7.

En síntesis, H1 se sostiene con holgura y H2 se sostiene con margen estrecho y bajo el criterio de cómputo declarado a priori. El sistema reduce el tiempo de procesamiento en un 83,4 % sobre documentos idénticos, magnitud que corresponde a la duración de la ejecución del flujo y no a la latencia extremo a extremo, según la acotación de la sección 3.3, y registra cuatro puntos porcentuales menos de discrepancias sobre el nombre y la cantidad de los artículos. La ventaja en exactitud no debe leerse, sin embargo, como una superioridad incondicional: el sistema modifica la naturaleza del error antes que suprimirlo, sustituyendo errores ortográficos de baja severidad operativa por errores de cantidad de consecuencia directa, y prescinde del control concurrente que el operador humano ejerce sobre su propio trabajo. La combinación de ambos procesos —revisión humana sobre salida automatizada— produciría previsiblemente una tasa inferior a la de cualquiera de ellos por separado.

5.6 Evaluación independiente y concordancia entre evaluadores

El protocolo previsto en la sección 5.1 contemplaba la verificación de una submuestra de los casos por un integrante del equipo distinto de quien había definido los valores esperados y ejecutado las corridas. Esta evaluación se realizó sobre ocho casos, equivalentes al

veinticinco por ciento de los casos computados, seleccionados de modo que comprendieran tanto casos verificados como correctos como casos en los que la primera evaluación había registrado discrepancias.

El segundo evaluador recibió, para cada caso, el documento de origen y la captura de la planilla generada por el sistema, y no tuvo acceso a los valores esperados consignados en el protocolo ni al resultado de la primera verificación. La evaluación se realizó, por tanto, a ciegas respecto del juicio previo. Tampoco se le comunicó el criterio de cómputo adoptado en la sección 5.1, circunstancia cuyas consecuencias se analizan más adelante.

Tabla 8

Concordancia entre evaluadores sobre la submuestra verificada

Caso	Evaluador 1	Evaluador 2	Coincidencia
CP-02	20/20	20/20	Sí
CP-05	20/20	20/20	Sí
CP-13	19/20	19/20	Sí
CP-15	20/20	10/20	No
CP-21	20/20	20/20	Sí
CP-27	20/20	20/20	Sí
CP-28	16/20	16/20	Sí
CP-31	15/20	15/20	Sí
Total	150/160	140/160	7 de 8

Nota. Elaboración propia. Cada celda consigna los campos computados como correctos sobre el total de campos verificados en el caso.

La concordancia alcanzó siete de los ocho casos evaluados. A nivel de campo individual, los dos evaluadores coincidieron en ciento cincuenta de ciento sesenta juicios, lo que arroja un acuerdo observado del 93,8 %. El coeficiente kappa de Cohen, que descuenta el acuerdo atribuible al azar, es de 0,64, valor que corresponde a una concordancia considerable en la escala de Landis y Koch (1977).

Los dos evaluadores coincidieron, sin excepción, en la totalidad de las discrepancias de contenido. El segundo evaluador identificó por su cuenta la singularización de «Milanesas de

ternera» en el caso CP-13, los dos artículos con la línea completa consignada como nombre y cantidad uno en el caso CP-28, y los cinco artículos singularizados en el caso CP-31. En el caso de CP-28, ambos evaluadores arribaron de forma independiente a la misma interpretación del error: el modelo tomó la línea completa como si designara un único producto, del modo en que se designaría una bolsa de alimento para perro de cuarenta kilogramos. La coincidencia en la interpretación, y no solo en el recuento, refuerza el diagnóstico consignado en la sección 5.3.

El único desacuerdo corresponde al caso CP-15, y su naturaleza resulta pertinente para el análisis de sensibilidad desarrollado en la sección 5.5. En ese caso el sistema persistió los diez artículos en minúscula inicial, donde el documento los consigna con mayúscula. El segundo evaluador, que desconocía el criterio de cómputo adoptado, computó las diez diferencias como error y consignó diez campos correctos sobre veinte. La primera evaluación, aplicando el criterio declarado en la sección 5.1, que excluye la capitalización por tratarse de una variación tipográfica que no altera la identidad del producto, consignó veinte sobre veinte.

El desacuerdo no revela un error de verificación sino una divergencia de criterio, y aporta evidencia empírica de que el criterio de cómputo no resulta evidente por sí mismo: un evaluador competente, examinando el mismo material sin conocerlo, arribó a la conclusión opuesta sobre precisamente el punto que el análisis de sensibilidad de la sección 5.5 había identificado como susceptible de alterar el contraste de la hipótesis H2. La observación justifica de manera concreta tanto la decisión de declarar el criterio de forma explícita como la de reportar el resultado que se obtendría bajo un criterio alternativo. Un trabajo que hubiera omitido esa declaración habría presentado como objetivo un recuento que depende de una convención no enunciada.

Corresponde consignar, por último, una verificación no prevista en el protocolo. Con anterioridad a la evaluación, y por un malentendido sobre el alcance de la tarea asignada, el

segundo evaluador procesó por el sistema el mismo pedido correspondiente al caso CP-13, empleando una instancia propia de la plataforma de orquestación, con credenciales, proyecto de identidad y carpetas de destino distintos de los utilizados en la ronda de validación. La ejecución resultó exitosa y persistió los diez artículos de forma literal, incluido «Milanesas de ternera» en plural, donde la ejecución registrada en CP-13 había persistido «Milanesa de ternera» en singular. El resultado tiene un doble valor. Por una parte, verifica que el flujo publicado resulta reproducible por un tercero en un entorno independiente. Por otra, constituye la demostración más directa del no determinismo documentado en la sección 5.3: el mismo documento, remitido por el mismo pipeline y procesado con el mismo prompt, produjo salidas distintas en dos ejecuciones. La observación no fue planificada, circunstancia que se consigna porque un resultado no buscado ofrece mayor garantía frente al sesgo de confirmación que uno diseñado para verificar la hipótesis.

5.6.1 Réplica de la evaluación con un evaluador externo al equipo

La evaluación precedente fue realizada por un integrante del equipo autor, circunstancia que la sección 5.7 consigna como limitación por cuanto ambos evaluadores comparten el interés en el resultado. Para acotarla se replicó la verificación con un tercer evaluador, Cinthia Rigoni, hermana de uno de los autores, ajena al equipo, sin participación alguna en el trabajo y sin vínculo con la carrera ni con la institución. El vínculo familiar se consigna de forma expresa: la evaluadora no integra el equipo autor ni tiene interés en la calificación, pero tampoco constituye un tercero enteramente desvinculado de los autores, y el lector debe ponderar el dato al interpretar los resultados. La verificación se realizó sobre los mismos ocho casos y bajo las mismas condiciones: recibió los documentos de origen y las planillas generadas en la ronda de validación, sin acceso a los valores esperados ni al resultado de ninguna de las

dos evaluaciones previas. A diferencia del segundo evaluador, el tercero sí recibió el criterio de cómputo declarado en la sección 5.1.

Los resultados de las tres evaluaciones se consignan en la Tabla 10. La evaluación del tercer evaluador no sustituye a la precedente: ambas se reportan por separado y ninguna se promedia con la otra.

Tabla 10

Concordancia entre los tres evaluadores sobre la submuestra verificada

Caso	Evaluador 1	Evaluador 2	Evaluador 3
CP-02	20/20	20/20	20/20
CP-05	20/20	20/20	20/20
CP-13	19/20	19/20	20/20
CP-15	20/20	10/20	10/20
CP-21	20/20	20/20	20/20
CP-27	20/20	20/20	20/20
CP-28	16/20	16/20	18/20
CP-31	15/20	15/20	10/20
Total	150/160	140/160	138/160

Nota. Elaboración propia. Cada celda consigna los campos computados como correctos sobre el total de campos verificados en el caso. El evaluador 1 corresponde a la primera verificación, el evaluador 2 al integrante del equipo y el evaluador 3 al evaluador externo.

Contrastada con la primera evaluación, la verificación externa arroja un acuerdo observado del 88,8 %, equivalente a ciento cuarenta y dos coincidencias sobre ciento sesenta juicios, y un coeficiente kappa de 0,38, valor que corresponde a una concordancia aceptable en la escala de Landis y Koch (1977). La concordancia con el evaluador externo resulta, por tanto, inferior a la obtenida entre los dos evaluadores del equipo, cuyo kappa es de 0,64. El dato se reporta por cuanto cuantifica precisamente aquello que la limitación consignada en la sección 5.7 advertía: la concordancia entre evaluadores que comparten el interés en el resultado sobrestima la fiabilidad de la verificación.

El contraste entre el segundo y el tercer evaluador resulta, sin embargo, el más informativo de los tres. Su acuerdo observado alcanza el 95,0 % y su kappa 0,78, de modo que concuerdan más entre sí que cualquiera de los dos con la primera evaluación. La explicación no reside en la atención ni en la competencia sino en el criterio: ambos computaron como error la ausencia de mayúscula inicial, que el criterio declarado en la sección 5.1 excluye de forma expresa. El segundo evaluador lo hizo en el caso CP-15, y el tercero en CP-15 y en CP-31.

La replicación de esa divergencia con un evaluador ajeno al equipo refuerza de manera considerable la observación formulada a propósito de CP-15. No se trata ya de que un evaluador haya arribado una vez a la conclusión opuesta sobre el punto que el análisis de sensibilidad había identificado como crítico, sino de que dos evaluadores independientes, que no participaron en la definición del criterio, aplicaron de forma espontánea la misma convención alternativa. La exclusión de la capitalización no resulta, por tanto, evidente por sí misma para quien examina el material sin conocer la decisión, y la sección 5.5 obra con acierto al declararla de forma explícita y al reportar el resultado que se obtendría bajo el criterio contrario.

Las divergencias restantes no responden a criterio sino a ejecución, y se consignan sin atenuación. En el caso CP-13 el evaluador externo no detectó la singularización de «Milanesas de ternera», que los dos evaluadores previos habían identificado de forma independiente. En el caso CP-28 computó dos errores donde los evaluadores previos computaron cuatro: identificó los mismos dos artículos y la misma causa —el modelo tomó el kilaje como parte de la denominación y asignó cantidad uno— pero contabilizó un error por artículo, mientras que el criterio de la sección 5.1 establece el campo como unidad de análisis, de modo que corresponden dos errores por artículo. El recuento de la primera evaluación es el correcto bajo el criterio declarado.

El conjunto de resultados acota la fiabilidad que cabe atribuir a una verificación realizada por un único evaluador. De los dieciocho juicios en que el evaluador externo difiere de la primera evaluación, quince obedecen a la aplicación de un criterio distinto y tres a una omisión. La verificación campo a campo resulta sensible tanto a la convención adoptada como a la atención del verificador, y ninguna de las dos fuentes de variación se elimina por completo mediante la declaración previa del criterio.

5.7 Limitaciones de la validación

No se aplicaron pruebas de inferencia estadística. El contraste de las hipótesis, desarrollado en la sección 5.5, se apoya en estadística descriptiva sobre una comparación pareada de diez documentos. La decisión responde a la naturaleza del corpus: los documentos fueron elaborados por el equipo de investigación con estructura deliberadamente homogénea, de modo que no constituyen una muestra aleatoria de una población de pedidos comerciales y no habilitan la estimación de parámetros poblacionales ni el cálculo de intervalos de confianza. Las proporciones reportadas describen el comportamiento observado sobre el corpus evaluado y no se extrapolan más allá de él. La línea de base manual se cronometró sobre diez de los veinte documentos del corpus, con un único operador de referencia. La comparación con un operador administrativo experimentado, o con varios operadores que permitieran estimar la variabilidad entre personas, queda fuera del alcance de esta instancia.

La verificación campo a campo de la totalidad de los casos fue realizada por un único evaluador, Matías Martínez, integrante del equipo de investigación, que es asimismo quien definió los valores esperados y quien ejecutó las corridas. Una submuestra del veinticinco por ciento fue verificada de forma independiente por un segundo evaluador, conforme se reporta en la sección 5.6, con una concordancia considerable. Subsiste, no obstante, la limitación de que ambos evaluadores integran el equipo de investigación y comparten, por tanto, el interés

en el resultado. La verificación fue replicada con un evaluador externo al trabajo, conforme se reporta en la sección 5.6.1; su concordancia con la primera evaluación resulta inferior a la obtenida entre los dos evaluadores del equipo, lo que cuantifica el alcance de esta limitación en lugar de suprimirla. Subsiste asimismo que el setenta y cinco por ciento de los casos cuenta con una única verificación.

Corresponde consignar, por último, una limitación de orden operativo observada durante el período de validación. Las credenciales de acceso a los servicios de correo y almacenamiento se gestionan mediante el protocolo OAuth2 sobre un proyecto configurado en modo de prueba, condición en la cual el token de actualización expira a los siete días y exige una reautorización manual del titular de la cuenta. Durante las semanas de ejecución de la validación, la caducidad del token interrumpió el funcionamiento del flujo en tres ocasiones, en cada una de las cuales las tres credenciales de Google debieron renovarse de forma simultánea. La limitación no es atribuible al diseño del flujo sino a la configuración del proyecto de credenciales, y se resuelve publicando la aplicación en el entorno del proveedor, lo que elimina la caducidad periódica. Se consigna, no obstante, porque en un despliegue productivo bajo la configuración evaluada el sistema requeriría intervención manual cada siete días, circunstancia incompatible con una operación desatendida.

La totalidad de los casos del corpus diseñado fue ejecutada, incluidos los cinco casos de borde: el documento escaneado sin texto embebido, el PDF anidado en un mensaje reenviado, el envío con dos adjuntos, el pedido con cantidades ambiguas y la ejecución con la carpeta de destino vacía. Sus resultados se analizan en la sección 5.3.

Los resultados corresponden a un corpus de documentos generados de forma sintética, de estructura homogénea, y a una única sesión de ejecución. La generación sintética introduce una limitación específica que conviene explicitar: los documentos fueron producidos mediante

un script elaborado con asistencia de un modelo de lenguaje y procesados luego por un modelo de lenguaje, de modo que su regularidad estructural podría resultar superior a la de un pedido redactado por una persona y favorecer el desempeño del sistema. Corresponde señalar, no obstante, que los defectos documentados en la sección 5.3 se manifestaron igualmente sobre este corpus regular, lo que permite suponer que su frecuencia no sería menor ante documentos de origen heterogéneo. No se ha evaluado el comportamiento del sistema ante documentos de proveedores reales con maquetación heterogénea, ni bajo carga concurrente, ni a lo largo del tiempo. La generalización de estos resultados a un entorno productivo requiere validación en ese contexto.

Las correcciones derivadas de los hallazgos se especifican en el Capítulo 7. Las limitaciones enunciadas en esta sección corresponden a la ronda ampliada. Su implementación y la segunda ronda de validación ejecutada sobre el sistema corregido se reportan en la sección 5.8, cuyo apartado final consigna las limitaciones propias de esa ronda, entre ellas el cambio de proveedor del modelo de lenguaje y sus consecuencias sobre el alcance de lo verificable.

5.8 Segunda ronda de validación tras la aplicación de las correcciones

Las correcciones especificadas en el Capítulo 7 se implementaron sobre el flujo y se sometieron a una segunda ronda de ejecución entre el 19 y el 28 de octubre de 2026. Esta ronda no constituye una nueva estimación de prevalencia de defectos ni resulta comparable con la anterior en términos agregados: es una ronda de regresión dirigida, con una muestra deliberadamente enriquecida en los casos que habían exhibido defecto, y sus resultados se reportan defecto por defecto y no como proporción de casos correctos. Las métricas de ambas rondas se registran por separado en el protocolo mediante la columna de versión del sistema y no se agregan entre sí.

La selección de casos se declaró antes de ejecutar y comprende diez: los ocho que habían manifestado defecto —CP-07, CP-08, CP-10, CP-17, CP-18, CP-19, CP-28 y CP-31— y dos controles de extracción que habían resultado correctos, CP-01 y CP-05, destinados a verificar la ausencia de regresión. La distribución es de cinco casos por pipeline. Por la razón expuesta, el porcentaje de casos sin defecto de esta ronda carece de significado comparativo y no se reporta.

5.8.1 Cambio del proveedor del modelo de lenguaje

La segunda ronda no pudo ejecutarse sobre el proveedor declarado en el Capítulo 4. A partir del 22 de septiembre de 2026 las llamadas de generación a la API de Mistral comenzaron a responder de forma invariable con el código 429 y el mensaje de límite de velocidad excedido. El diagnóstico se desarrolló por descarte y consta en el registro de ejecuciones. Se verificó en primer término que la credencial fuese válida, dado que la prueba de conexión de la plataforma de orquestación resultaba satisfactoria. Se comprobó a continuación que el comportamiento no dependía de la cuenta: tres cuentas distintas, una de ellas creada ese mismo día y con su asignación mensual íntegra, devolvieron la misma respuesta. Se verificó que tampoco dependía del saldo, puesto que el error persistió tras la carga de crédito y tras la reposición de la asignación mensual del 1 de octubre. Por último se reprodujo el error mediante llamadas directas a la API desde una terminal, al margen de la plataforma de orquestación, lo que descarta que la causa resida en el flujo o en su configuración.

Al mismo tiempo se constató que el identificador mistral-small, con el que el Pipeline B había operado durante la ronda ampliada por tratarse del valor predeterminado del nodo, había dejado de figurar entre los modelos seleccionables. La configuración efectivamente medida resultó por tanto irrecuperable: un flujo cuyo comportamiento dependía de un valor

predeterminado no declarado del proveedor dejó de ser reconstruible por sus propios autores a menos de dos meses de las mediciones.

Se adoptó en consecuencia Google Gemini, en el modelo gemini-3.6-flash, con la temperatura fijada en cero. Los criterios de selección fueron la disponibilidad de un nivel gratuito sin requisito de medio de pago, la existencia de un nodo nativo en la plataforma de orquestación que no obligara a modificar la arquitectura del flujo, y el soporte de salida estructurada conforme a esquema, condición necesaria para que los analizadores de ambos pipelines continuaran operando sin cambios. No se realizó una evaluación comparativa sistemática entre proveedores: la decisión responde a la indisponibilidad del proveedor original y se consigna como criterio de selección y no como resultado del trabajo.

El cambio acota el alcance de esta ronda y la limitación debe declararse con precisión. La precisión de extracción obtenida sobre Gemini no es comparable con la obtenida sobre Mistral, de modo que ninguna diferencia observada en la calidad de la extracción puede atribuirse a las correcciones aplicadas. En particular, el defecto de extracción no reproducible por ausencia de temperatura fijada no resulta verificable en las condiciones originales, dado que el modelo sobre el que se manifestó ya no se encuentra disponible. Los casos CP-28 y CP-31, que en la ronda ampliada habían registrado alteraciones léxicas, no las repiten en esta ronda; esa ausencia se atribuye al cambio de proveedor y no a las correcciones, y así se consigna en el registro.

Lo que sí resulta verificable es el conjunto de defectos de orquestación, que son independientes del modelo empleado. Que la unidad se persista, que la planilla de destino se identifique de forma unívoca, que el flujo se interrumpa ante un correo que no constituye un pedido y que la excepción se notifique no dependen de qué proveedor realice la extracción, sino de la topología del flujo y de la configuración de sus nodos. Sobre esos cuatro defectos la

segunda ronda conserva plena capacidad de verificación, y es sobre ellos que se reportan sus resultados.

El cambio incorporó además una mejora no buscada en el diseño experimental. La ronda ampliada había declarado como variable no controlada el hecho de que ambos pipelines operaran sobre modelos distintos, mistral-medium el Pipeline A y mistral-small el Pipeline B. En la segunda ronda ambos operan sobre gemini-3.6-flash con idéntica configuración, de modo que esa variable queda controlada.

5.8.2 Resultados por defecto

La emisión de confirmación ante correos que no constituyen pedidos se verifica corregida. Los casos CP-17 y CP-18 fueron derivados por la rama negativa del nodo de corte, no persistieron fila alguna y no generaron acuse al remitente. Los dos estímulos presentan dificultad distinta de forma deliberada: CP-17 es una consulta comercial que menciona rubros y condiciones de pago, y CP-18 un mensaje de cortesía sin contenido comercial alguno. La corrección discrimina por tanto la clase y no un texto particular.

La extracción de la unidad sin su persistencia se verifica corregida. Los casos CP-01 y CP-05, que en la ronda ampliada habían registrado veinte campos correctos sobre treinta por la pérdida de ese campo, alcanzan en esta ronda treinta sobre treinta, con la unidad de los diez ítems registrada en la planilla. No se observó regresión en los campos de artículo ni de cantidad.

La ausencia de identificación unívoca de la planilla de destino se verifica corregida en los diez casos. La sustitución de la búsqueda en la carpeta por la referencia directa al identificador que devuelve el nodo de traslado elimina la ambigüedad por construcción y no por disponibilidad: ya no existe una consulta cuyo resultado dependa del orden en que el servicio de almacenamiento devuelva los archivos.

La ausencia de correspondencia verificable entre lo procesado y lo comunicado se verifica mitigada y no corregida. La mitigación opera en el Pipeline B: la rama negativa del nodo de corte emite una notificación interna que consigna el motivo del rechazo, el remitente y el asunto, y retira la etiqueta del mensaje. Dos casos de esta ronda delimitan el alcance de esa mitigación y se exponen en el apartado 5.8.4.

5.8.3 Hallazgos de la segunda ronda

La ejecución de las correcciones produjo cuatro resultados que la especificación del Capítulo 7 no podía anticipar, por cuanto solo se manifiestan al ejecutar el flujo corregido.

El primero es que el nodo de corte, en su implementación inicial, no evitaba la creación del artefacto de destino. La rama que crea la planilla dependía del nodo de bifurcación inicial y no de la clasificación, de modo que un correo rechazado dejaba igualmente una planilla vacía en la carpeta de destino. El defecto se detectó al observar ese artefacto tras la ejecución de CP-17. Se corrigió haciendo depender la rama de creación de la salida afirmativa del nodo de corte, y se verificó en CP-18 y en CP-17: ninguno de los dos generó planilla, y la duración del rechazo descendió de 25,7 a 4,8 segundos. La corrección tiene además un efecto compuesto, dado que cada planilla huérfana incrementaba el conjunto de candidatas que la consulta de destino podía devolver.

El segundo es que la rama negativa no retiraba la etiqueta del mensaje procesado, con lo cual la idempotencia del sistema, que este capítulo documenta como delegada en el estado del correo, quedaba rota precisamente para los casos rechazados. Se incorporó el retiro de etiqueta a continuación de la notificación y se verificó en CP-17, CP-18 y CP-08.

El tercero es un defecto preexistente que la reestructuración anterior hizo manifiesto. Al pasar a depender del nodo de corte, la rama de creación comenzó a recibir un ítem por

artículo en lugar de uno por correo, lo que provocaba su ejecución repetida. El defecto no fue introducido por la corrección: permanecía latente mientras esa rama dependiera del nodo de bifurcación, que entrega siempre un único ítem. Es el mismo mecanismo que mantenía latente al defecto de identificación de la planilla, a saber, el aislamiento entre ramas que no comparten dependencia de datos. Se corrigió restringiendo la ejecución del primer nodo de la rama a una sola vez y sustituyendo sus referencias relativas por referencias absolutas al disparador.

El cuarto es el más relevante y afecta a la corrección del falso positivo. El caso CP-19, un pedido redactado sin cantidades numéricas, fue clasificado como no pedido y derivado por la rama negativa. La clasificación constituye un falso negativo: el documento es un pedido legítimo al que le faltan las cantidades. El clasificador binario incorporado para resolver el falso positivo introduce por tanto el modo de falla inverso, de modo que un pedido real e incompleto se descarta por completo en lugar de registrarse como incompleto. El resultado no invalida la corrección, dado que en la ronda ampliada ese mismo caso persistía una fila vacía sin señal alguna y ahora no persiste nada y notifica, pero acota su alcance: el pedido sigue sin llegar a destino y el remitente sigue sin recibir aviso. Corresponde señalar asimismo que el modelo no fabricó cantidades, que era el riesgo que el caso se proponía explorar.

5.8.4 Alcance de la mitigación del defecto transversal

Dos casos de esta ronda delimitan hasta dónde alcanza la mitigación del defecto transversal, y ambos corresponden al Pipeline A, que no incorpora nodo de corte por cuanto su esquema de salida no declara el campo de clasificación.

En CP-10, un correo con dos documentos adjuntos, el flujo procesó únicamente el primero y persistió sus diez ítems de forma correcta. El segundo documento no se procesó, no se persistió y no generó excepción. El acuse enviado al remitente informa en términos genéricos

que el pedido fue recibido, sin enumerar artículos, cantidades ni número de documentos procesados, de modo que el remitente no dispone de elemento alguno para advertir que la mitad de lo que envió se perdió. Es la formulación más precisa del defecto transversal que la validación ha producido: no se trata de que el sistema falle, sino de que informa un resultado que no permite verificar lo ocurrido. Ninguna de las correcciones aplicadas lo alcanza, dado que el corte opera sobre la clasificación del contenido ya extraído y no sobre el número de adjuntos recibidos.

En CP-07, un documento sin capa de texto, el nodo de extracción completó su ejecución sin error, reportó correctamente la página y los metadatos del archivo, y devolvió el campo de texto vacío. El modelo recibió una cadena vacía y devolvió la estructura del esquema sin ítems, sin fabricar artículos ni cantidades. El nodo de transformación no produjo salida y la rama se interrumpió antes de la escritura y del acuse. La planilla de destino se creó igualmente, con sus encabezados y ninguna fila, y la ejecución figura como exitosa. El caso precisa el diagnóstico que la ronda ampliada había consignado: el fallo no consiste en que la lectura del documento se interrumpa, sino en que termina con éxito y devuelve vacío, y el flujo prosigue sobre esa base sin señalar nada.

Ambos casos muestran que la mitigación es parcial y está circunscripta al Pipeline B. La vía de solución para el Pipeline A se encuentra identificada —incorporar el campo de clasificación a su esquema de salida y un nodo de corte homólogo— y no se implementó en esta ronda por exceder lo especificado en el Capítulo 7.

5.8.5 Condiciones de ejecución y limitaciones de esta ronda

Cuatro condiciones del entorno difieren entre ambas rondas y se declararon antes de ejecutar: el proveedor y el modelo de lenguaje, conforme se expuso; la carpeta de destino del

documento adjunto, modificada con posterioridad a la ronda ampliada, que no incide sobre la extracción ni sobre la persistencia; las credenciales de acceso al servicio de correo, rehechas el 22 de septiembre de 2026 tras su caducidad; y el estado de facturación de la cuenta del proveedor original, que resultó irrelevante al no restablecer el acceso.

Dos estímulos difieren de los empleados en la ronda ampliada. En CP-08 se verificó que el reenvío de un mensaje con documento adjunto no produce la condición buscada, por cuanto el cliente de correo reasigna el adjunto al primer nivel; se adoptó en consecuencia la alternativa prevista en el protocolo, consistente en enviar un enlace al documento. En CP-07 el documento sin capa de texto se generó por rasterización del original a doscientos puntos por pulgada con artefactos simulados de digitalización, y no por digitalización física. En ambos casos la condición ensayada es equivalente en lo esencial pero no idéntica, y la comparación directa con la ronda ampliada queda acotada en consecuencia.

Corresponde consignar por último que la ejecución de esta ronda estuvo condicionada por seis incidentes de disponibilidad de servicios externos, ninguno atribuible al diseño del sistema y todos registrados con fecha e identificador de ejecución: la caducidad de las credenciales del servicio de correo, la retirada del identificador de modelo empleado en la ronda ampliada, la indisponibilidad sostenida de la API del proveedor original, la imposibilidad de publicar la aplicación en el proveedor de identidad por exigir un proceso de verificación, la retirada del primer modelo de reemplazo para cuentas nuevas y los rechazos por saturación del proveedor adoptado. El Capítulo 6 retoma esta serie, por cuanto incide directamente sobre la reproducibilidad que este trabajo declara como aporte.

Capítulo 6: Discusión

La validación ampliada permite sostener que la combinación de orquestación de flujos, procesamiento de documentos mediante un modelo de lenguaje y validación de esquema estructurado resulta técnicamente viable para la ingesta automatizada de pedidos comerciales. Sobre treinta y dos casos computados, el sistema procesó la totalidad de los documentos sin excepciones atribuibles a su diseño. Corresponde precisar el alcance de esta afirmación: lo verificado es el funcionamiento extremo a extremo del flujo sobre un corpus sintético de estructura homogénea, y la mejora en tiempo respecto de un operador humano de referencia sobre esos mismos documentos. La generalización a operadores con distinto grado de destreza, a documentos de maquetación heterogénea o a un entorno productivo excede lo que estos datos permiten sostener.

En diálogo con la literatura, Lacity y Willcocks (2016) documentan beneficios operativos derivados de la automatización de procesos en un caso organizacional de gran escala. El presente trabajo dispone de una medición del proceso manual de referencia, reportada en la sección 5.4, pero no se encuentra en condiciones de comparar magnitudes con ese estudio: la diferencia de escala y de contexto organizacional entre una implementación en una organización de gran porte y una evaluación funcional sobre un corpus sintético impide que ambas cifras resulten conmensurables. Lo que sí resulta consistente con la línea descrita por Davenport y Kirby (2016) es el desplazamiento del rol humano desde la ejecución de la tarea hacia la supervisión de excepciones, patrón que orienta el diseño del circuito de escalamiento proyectado, cuya implementación no forma parte de la versión evaluada. Respecto del enfoque técnico, el uso de prompt engineering estructurado sobre un modelo alojado constituye una alternativa al ajuste fino en entornos donde la disponibilidad de corpus anotados es limitada; evaluar comparativamente ambos enfoques excede el alcance de este trabajo. Los resultados

obtenidos son consistentes con lo reportado por Dagdelen et al. (2024), quienes verifican que un modelo de lenguaje guiado por prompt puede convertir texto no estructurado en registros validados sin reentrenamiento específico de dominio, y con Xu et al. (2024) en cuanto al desplazamiento de la extracción de información hacia enfoques generativos. La variabilidad entre ejecuciones documentada en la sección 5.3 coincide con la sensibilidad que Chen et al. (2025) atribuyen a la configuración del prompt y del modelo en tareas de extracción documental, y admite en este caso una explicación precisa: la ausencia de un parámetro de temperatura fijado en los nodos del flujo. Krieger et al. (2023) describen, para el dominio de facturas de proveedores heterogéneos, dificultades de variación de formato análogas a las que motivaron la construcción de un corpus con rubros diversos en el presente trabajo.

Desde el punto de vista práctico, el aporte del trabajo es una arquitectura documentada y replicable para la ingesta automatizada de pedidos, junto con un protocolo de validación que resultó capaz de detectar defectos que la inspección del flujo exportado no había precisado. Dos de los cinco defectos identificados no son detectables por lectura del código: la no reproducibilidad de la extracción requiere repetir un mismo caso en ejecuciones distintas para manifestarse, y la ambigüedad del dato persistido por omisión de la unidad solo se advierte al contrastar la planilla contra documentos que emplean unidades de venta distintas de la unidad individual. Este punto es pertinente para el diseño de sistemas equivalentes: la distribución de los hallazgos sugiere que el riesgo de las arquitecturas que integran modelos de lenguaje en flujos de negocio no reside principalmente en la capacidad del modelo, que en los casos verificados interpretó correctamente la estructura del pedido y se abstuvo de fabricar campos ausentes, sino en la capa de orquestación y persistencia que lo rodea. No se estimó el retorno de la inversión, dado que el trabajo no releva costos de implementación, horas de desarrollo, costo de la API ni valor hora del personal. Las limitaciones propias de una validación funcional en entorno controlado no se ven mitigadas por la profundidad del caso: la validez externa de

los resultados permanece acotada y su generalización requiere validación en contextos organizacionales reales.

La segunda ronda de validación, reportada en la sección 5.8, añadió a ese cuadro una tercera capa de riesgo que la ronda ampliada no había podido observar, por cuanto solo se manifiesta con el transcurso del tiempo. Entre el 22 de septiembre y el 28 de octubre de 2026 se registraron seis incidentes de disponibilidad de servicios externos, ninguno atribuible al diseño del sistema y todos ellos impeditivos de su funcionamiento.

Las credenciales de acceso al servicio de correo caducaron, conforme a la limitación de siete días que afecta a las aplicaciones en estado de prueba. El identificador del modelo con el que había operado el Pipeline B dejó de figurar entre los seleccionables. La interfaz del proveedor de lenguaje declarado en el Capítulo 4 dejó de responder a las llamadas de generación, comportamiento que se verificó independiente de la credencial, de la cuenta y del saldo. La publicación de la aplicación en el proveedor de identidad, especificada como corrección en el Capítulo 7 para eliminar la caducidad de credenciales, resultó inaplicable por exigir un proceso de verificación que los permisos requeridos por el diseño vuelven obligatorio. El primer modelo adoptado como reemplazo fue retirado para cuentas nuevas. Y el modelo finalmente empleado devolvió rechazos por saturación en varias ocasiones.

La consecuencia más significativa no es la interrupción sino la pérdida de la configuración medida. El Pipeline B había operado durante la ronda ampliada sobre el valor predeterminado del nodo, sin declararlo; al retirarse ese identificador del catálogo del proveedor, la configuración sobre la cual se obtuvieron los resultados dejó de ser reconstruible por los propios autores a menos de dos meses de las mediciones. El defecto de extracción no reproducible quedó, por esa vía, sin posibilidad de verificación en las condiciones originales.

Este hecho obliga a calificar el aporte que la sección 2.5 declara. El trabajo publica el corpus, el protocolo, el registro por caso y el flujo exportado bajo un identificador permanente, y en ese sentido la ronda reportada es verificable por terceros. Pero la reproducibilidad de un sistema cuyo componente central es un servicio de terceros no depende únicamente de que sus artefactos estén publicados: depende también de que el servicio conserve sus condiciones de acceso, su catálogo de modelos y su esquema de autenticación, ninguno de los cuales está bajo control de quien publica. Un flujo de estas características tiene, en consecuencia, una fecha de vencimiento que sus autores no fijan ni conocen.

La observación excede al caso evaluado y resulta pertinente para el diseño de arquitecturas equivalentes. A la recomendación de declarar de forma explícita toda la configuración del modelo, que el Capítulo 7 especifica como corrección, se agrega la de considerar la dependencia de servicios externos como un riesgo de diseño y no como un detalle de implementación. Para una organización del porte que este trabajo toma como contexto de aplicación, la restricción es doblemente onerosa: el proceso de verificación que habilitaría credenciales estables exige recursos de los que una organización pequeña rara vez dispone, de modo que la alternativa practicable queda limitada a operar de forma permanente bajo condiciones de prueba, con la inestabilidad que ello supone.

En síntesis, la hipótesis H1 se sostiene sobre el corpus evaluado, con una reducción del tiempo de procesamiento del 83,4 % verificada por comparación pareada sobre documentos idénticos, referida a la duración de la ejecución del flujo y no a la latencia extremo a extremo, conforme se acota en la sección 3.3, y H2 se sostiene con margen estrecho y bajo el criterio de cómputo declarado a priori, con cuatro puntos porcentuales de diferencia en favor del sistema. La conclusión de H2 es sensible al tratamiento de las diferencias ortográficas, según se expone en la sección 5.5. Los resultados obtenidos permiten sostener la viabilidad técnica de la

arquitectura propuesta, identifican cinco defectos con su localización precisa en el flujo, y delimitan el alcance de lo verificado. Las correcciones especificadas en el Capítulo 7 fueron implementadas y sometidas a una segunda ronda, reportada en la sección 5.8, que verifica el cierre de cuatro de los cinco defectos, acota la mitigación del defecto transversal al Pipeline B e identifica un modo de falla inverso introducido por la propia corrección del falso positivo. Resta como trabajo pendiente la extensión del circuito de corte al Pipeline A y la incorporación de validaciones de plausibilidad sobre el contenido extraído. La evaluación de una submuestra por un segundo evaluador, prevista en el protocolo, fue ejecutada y se reporta en la sección 5.6.

Capítulo 7: Conclusiones y Recomendaciones

La implementación del sistema de automatización inteligente permitió verificar que es viable procesar pedidos comerciales sin intervención manual en aquellos casos que superan la validación de esquema estructurado, y que la arquitectura admite derivar a revisión humana los casos que no la superan, si bien ese circuito no llegó a implementarse en la versión evaluada y ningún caso fue efectivamente derivado por el sistema durante la validación. La validación ampliada reportada en el Capítulo 5 verificó este comportamiento sobre treinta y dos casos, de los cuales el 71,9 % se procesó sin defecto detectado, e identificó cinco defectos de la capa de orquestación cuya corrección se especifica más adelante en este capítulo. El Capítulo 6 contrasta estos resultados con los antecedentes relevados y precisa en qué aspectos admiten comparación y en cuáles no. Sobre esa base, el enfoque permitiría liberar recursos humanos para tareas de mayor valor agregado, tales como análisis de mercado, atención personalizada al cliente y mejora continua de procesos, en una magnitud consistente con la reducción del 83,4 % del tiempo de procesamiento verificada en la comparación pareada de la sección 5.4.

Como recomendaciones concretas y accionables se propone: extender la solución a otros procesos administrativos de alto volumen documental tales como facturación electrónica, reclamos de clientes y conciliaciones bancarias; implementar un esquema de versionado del prompt de sistema y del esquema de salida, con pruebas de regresión sobre un conjunto fijo de documentos ante cada cambio de versión del modelo o del prompt, dado que el sistema no entrena un modelo propio sino que consume un modelo alojado por un tercero; capacitar al personal administrativo en roles de supervisión y manejo de excepciones mediante un programa de formación específico, cuya extensión deberá dimensionarse en función del volumen documental y del perfil del personal de cada organización; y realizar auditorías periódicas de seguridad y cumplimiento normativo de las APIs y flujos automatizados conforme a las normas ISO 27001 y Ley 25.326.

Correcciones derivadas de la validación

La validación ampliada identificó cinco defectos, cada uno localizado en un nodo específico del flujo. Se especifican a continuación las correcciones correspondientes, ordenadas por la gravedad de la consecuencia que evitan. Las cinco fueron implementadas sobre el flujo y sometidas a una segunda ronda de validación entre el 19 y el 28 de octubre de 2026, reportada en la sección 5.8. La especificación se conserva en los términos en que fue formulada a partir de la ronda ampliada, y el estado de cada corrección tras su aplicación se consigna al cierre de este apartado.

La primera corrección consiste en fijar el parámetro de temperatura en cero y declarar de forma explícita el modelo empleado en los dos nodos de modelo del flujo. En su configuración actual, ambos nodos presentan el objeto de opciones vacío, de modo que operan con el valor por defecto del proveedor y la extracción no resulta reproducible entre invocaciones. Esta corrección es condición previa a las restantes: las pruebas de regresión sobre

un conjunto fijo de documentos, ya recomendadas en el apartado anterior, carecen de sentido mientras una misma entrada pueda producir salidas distintas. Corresponde señalar que fijar la temperatura en cero reduce la variabilidad pero no garantiza determinismo absoluto en una interfaz de terceros, por lo que las pruebas de regresión deben admitir una tolerancia y no exigir identidad literal.

La segunda corrección consiste en sustituir la búsqueda del archivo de destino por la referencia directa al identificador que devuelve el nodo de creación de la planilla. La consulta actual solicita a la interfaz de almacenamiento un archivo de tipo hoja de cálculo contenido en la carpeta de destino, con límite de un resultado, sin filtrar por nombre ni por identificador propio, de modo que la correspondencia entre la planilla creada y la escrita depende del orden de resultados que devuelva el proveedor. La referencia directa elimina esa dependencia y hace innecesaria la espera fija que el flujo introduce como mitigación. Complementariamente, se recomienda incorporar al título de la planilla el número de pedido y la marca temporal, de modo que los archivos generados por un mismo remitente resulten distinguibles sin necesidad de abrirlos.

La tercera corrección consiste en incorporar al esquema de salida un campo que declare si el texto recibido constituye un pedido, y en sustituir la guarda del nodo de transformación por un nodo de corte que interrumpa el flujo antes de la persistencia y del envío de la confirmación cuando ese campo sea negativo. La incorporación de ese campo exige un cambio previo en la modalidad de definición del esquema: conforme se observa en la Captura C.6 del Anexo C, el esquema del Pipeline B se define mediante generación a partir de un ejemplo en formato JSON, modalidad en la cual todas las propiedades declaradas resultan obligatorias. Un campo que indique la ausencia de pedido debe poder coexistir con un arreglo de ítems vacío, lo que requiere migrar la definición a la modalidad de esquema JSON explícito, que admite

propiedades opcionales. La guarda actual incorpora una fila con producto vacío y cantidad cero cuando la lista devuelta por el modelo viene vacía, lo que convierte una respuesta correcta del modelo en un registro espurio y en una confirmación comercial improcedente. Ambos cambios son necesarios: el campo por sí solo no evita que la guarda fabrique la fila.

La cuarta corrección consiste en incorporar la unidad de medida al mapeo de columnas del nodo de escritura del Pipeline A. El campo se encuentra definido en el esquema de salida y es proyectado por el nodo de transformación, pero no figura entre las columnas mapeadas, por lo que se descarta antes de la planilla. Su omisión vuelve ambiguo el dato persistido en todos los casos en que la unidad de venta no coincide con la unidad individual. Se recomienda asimismo persistir los campos de cabecera —número de pedido, fecha y cliente—, que el modelo extrae correctamente y que el flujo descarta al proyectar únicamente las líneas de ítem, dado que su ausencia delega la identificación del pedido en el nombre del archivo.

La quinta corrección es de configuración y no de diseño: corresponde publicar la aplicación en el entorno del proveedor de identidad, de modo que el token de actualización deje de expirar a los siete días. Bajo la configuración de prueba empleada durante la validación, la caducidad periódica interrumpe el flujo y exige la reautorización manual de las tres credenciales, según se consigna en la sección 5.7. Cualquier despliegue destinado a operar de forma desatendida requiere resolver esta condición con anterioridad, junto con un mecanismo de alerta que notifique la interrupción del servicio, ausente en la versión evaluada.

Estado de las correcciones tras su aplicación

Las cinco correcciones precedentes se implementaron sobre el flujo y se verificaron en la segunda ronda reportada en la sección 5.8. Se consigna a continuación el estado de cada una,

por cuanto la especificación formulada a partir de la ronda ampliada no anticipó la totalidad de las consecuencias de su aplicación.

La primera corrección se aplicó en ambos nodos de modelo, pero no resulta verificable en las condiciones originales. El proveedor declarado en el Capítulo 4 dejó de responder a las llamadas de generación y el identificador con el que operaba el Pipeline B dejó de estar disponible, de modo que la segunda ronda se ejecutó sobre otro proveedor. La temperatura quedó fijada en cero y el modelo declarado de forma explícita en ambos pipelines, que es lo que la corrección prescribe, pero la reproducibilidad de la extracción no pudo contrastarse contra el comportamiento que motivó el diagnóstico.

La segunda corrección se aplicó en los dos pipelines y se verifica en los diez casos de la segunda ronda. La recomendación complementaria de incorporar el número de pedido al título de la planilla no se implementó: ese dato se produce en la etapa de extracción, posterior a la creación del archivo, de modo que no se encuentra disponible en el momento en que el título se construye. La distinguibilidad de los archivos generados por un mismo remitente queda, en consecuencia, sin resolver.

La tercera corrección se aplicó en el Pipeline B conforme a lo especificado, incluida la migración del esquema a la modalidad explícita, y se verifica en los casos CP-17 y CP-18. Su aplicación reveló, sin embargo, dos condiciones que la especificación no contemplaba y un efecto adverso. Las dos condiciones dieron lugar a las correcciones sexta y séptima que se enuncian más abajo. El efecto adverso consiste en que el clasificador binario introduce el modo de falla inverso al que corrige: el caso CP-19, un pedido legítimo redactado sin cantidades numéricas, fue descartado por completo en lugar de registrarse como incompleto. La corrección resuelve el falso positivo y abre el falso negativo, circunstancia que debe considerarse al extender el mecanismo.

La cuarta corrección se aplicó en el Pipeline A y se verifica en los casos CP-01 y CP-05, que pasan de veinte campos correctos sobre treinta a treinta sobre treinta. Su aplicación exigió dos cambios no previstos: la columna debe incorporarse también al nodo que escribe la fila de encabezado, dado que el flujo crea la planilla vacía en cada ejecución, y el nodo de escritura debió pasar a correspondencia automática de columnas, por cuanto la modalidad manual no puede leer los encabezados de un destino que se resuelve en tiempo de ejecución. La recomendación complementaria de persistir los campos de cabecera no se implementó, por exceder el alcance de la especificación y alterar los denominadores de cómputo a mitad de ronda.

La quinta corrección no resultó aplicable. La publicación de la aplicación en el entorno del proveedor de identidad exige completar la información de marca y someterse a un proceso de verificación que los permisos requeridos por el diseño —lectura y modificación de mensajes, acceso a almacenamiento y a hojas de cálculo— vuelven obligatorio. Ese proceso excede el alcance del presente trabajo. La caducidad de credenciales no constituye, por tanto, un defecto de configuración que se resuelva con una opción, sino una restricción estructural para todo sistema de estas características desarrollado fuera de una organización con recursos para certificarse, conforme se desarrolla en el Capítulo 6.

La sexta corrección, no prevista en la especificación, consiste en hacer depender la rama de creación de la planilla de la salida afirmativa del nodo de corte y no del nodo de bifurcación inicial. Sin ella, el corte evita la persistencia y el acuse pero no la creación del artefacto, de modo que cada correo rechazado deja una planilla vacía en la carpeta de destino y alimenta el defecto que la segunda corrección resuelve. Se verifica en los casos CP-17 y CP-18.

La séptima corrección, tampoco prevista, consiste en retirar la etiqueta del mensaje en la rama negativa del corte. Sin ella, la idempotencia del flujo, delegada en el estado del correo, queda rota precisamente para los casos rechazados. Se verifica en CP-17, CP-18 y CP-08.

Resta pendiente la extensión del mecanismo de corte al Pipeline A, que exige incorporar el campo de clasificación a su esquema de salida, junto con las validaciones de plausibilidad enunciadas a continuación. Los casos CP-07 y CP-10 de la segunda ronda acreditan que, sin esas dos medidas, el defecto transversal permanece sin mitigar en ese pipeline.

Con independencia de las correcciones anteriores, la validación puso de manifiesto una carencia de diseño más general: el flujo no dispone de ningún mecanismo capaz de señalar que una extracción fue incorrecta. El error registrado en el caso CP-28, en el que el modelo asignó cantidad uno a dos artículos cuyas cantidades reales eran cuarenta y veinticinco, resultó indetectable para la validación de esquema, dado que tanto el nombre como la cantidad constituían valores sintácticamente válidos. Se recomienda incorporar validaciones de plausibilidad sobre los datos extraídos —rangos admisibles por tipo de artículo, coherencia entre el número de ítems detectados y el número de líneas del documento de origen, señalamiento de cantidades atípicas respecto del historial del cliente— y derivar a revisión humana los casos que las incumplan, en lugar de confiar la detección de errores exclusivamente a la validación estructural del esquema.

Futuras investigaciones podrían explorar, con el mismo rigor metodológico aplicado en el presente estudio, las siguientes líneas de desarrollo y profundización del sistema SAPP y de la hiperautomatización aplicada al sector comercial.

Integración de trazabilidad inmutable mediante blockchain

La incorporación de una capa de trazabilidad basada en tecnología blockchain permitiría garantizar la inmutabilidad del registro de cada pedido desde su recepción hasta su confirmación en Google Sheets, eliminando la posibilidad de modificaciones no auditadas en el historial de transacciones. Esta línea es especialmente relevante en contextos regulatorios o de auditoría fiscal donde la integridad documental constituye un requisito legal, como es el caso de las obligaciones de facturación electrónica y conservación de comprobantes establecidas por la AFIP para el sector comercial argentino. La integración técnica implicaría agregar un nodo de escritura en cadena al final del pipeline exitoso de SAPP, de manera que cada pedido registrado en Google Sheets genere simultáneamente un hash inmutable en una red blockchain de bajo costo operacional. El principal desafío técnico radica en la latencia introducida por la escritura en cadena, que podría afectar los tiempos de procesamiento registrados en la validación ampliada, y en la selección de una red con costo por transacción compatible con el volumen de operaciones diarias de una PyME.

Manejo autónomo de excepciones mediante agentes de IA generativa

El diseño del sistema SAPP previó derivar a revisión manual los pedidos cuyo esquema JSON no supera la validación del Structured Output Parser, circuito que, conforme se detalla en la sección 4.2, no llegó a implementarse en la versión evaluada. Durante la validación preliminar esta situación se presentó en el caso documentado como excepción, asociado a un documento PDF que no fue recibido por el flujo como archivo binario adjunto. Un agente de IA generativa con capacidad de razonamiento multi-paso podría abordar estas situaciones de manera autónoma, intentando estrategias alternativas de extracción antes de escalar al operador humano: por ejemplo, solicitar al modelo una segunda interpretación con instrucciones más permisivas, aplicar OCR avanzado sobre la imagen del documento, o consultar el historial de pedidos del mismo cliente para inferir los campos faltantes por contexto. Esta extensión podría

reducir la proporción de casos derivados a revisión manual, aunque su magnitud no puede estimarse a partir de los datos disponibles en este trabajo. El desafío principal es el costo computacional y la latencia de los modelos de razonamiento avanzado en entornos de producción de alto volumen, así como la necesidad de establecer criterios claros de escalado para los casos que genuinamente requieran juicio humano.

Extensión a otros procesos administrativos de alto volumen documental

El protocolo de diagnóstico, diseño, implementación y evaluación desarrollado en el presente trabajo constituye un modelo replicable que podría aplicarse a otros procesos administrativos en organizaciones del mismo sector. Los procesos con mayor potencial de automatización inmediata son la conciliación bancaria, donde los extractos en PDF o CSV podrían procesarse con el mismo pipeline de extracción de entidades; la gestión de reclamos de clientes, donde los correos de queja podrían clasificarse y derivarse automáticamente según su naturaleza; y la facturación electrónica, donde la generación y envío de comprobantes podría integrarse directamente al flujo actual de SAPP como una capa de salida adicional. Cada una de estas extensiones requeriría una fase de diagnóstico específica para mapear las particularidades del proceso objetivo, seguida de un ajuste del prompt de extracción y del esquema JSON de salida.

Validación en contextos organizacionales diversos

Dado que el presente estudio corresponde a una validación funcional en entorno controlado, sobre un corpus sintético y sin implementación en una organización real, la generalización de los resultados requiere validación en otros contextos. Futuras investigaciones deberían replicar el protocolo en organizaciones de distintos tamaños, sectores y regiones geográficas, con especial atención a contextos donde la variabilidad documental sea aún mayor que la observada en el corpus utilizado en este trabajo. La comparación sistemática de los resultados entre distintos contextos permitiría identificar los factores organizacionales y

tecnológicos que moderan el impacto de la hiperautomatización, contribuyendo al desarrollo de un modelo predictivo de éxito para implementaciones similares en el ecosistema de PyMEs latinoamericanas.

Síntesis final

El presente trabajo verifica que la convergencia entre automatización de procesos de negocio, modelos de lenguaje aplicados a documentos y arquitecturas de integración por APIs constituye una vía técnicamente viable para abordar el procesamiento manual de pedidos en el sector comercial argentino. Los resultados obtenidos corresponden a una validación funcional en entorno controlado sobre un corpus de veinte documentos y treinta y dos casos computados, complementada con una línea de base del proceso manual cronometrada sobre diez de esos documentos. La comparación pareada, reportada en la sección 5.4, acredita una reducción del tiempo de procesamiento del 83,4 % y sostiene la hipótesis H1. La hipótesis H2, referida a la tasa de error, se sostiene con margen estrecho y con la salvedad de sensibilidad que se analiza en la sección 5.5. La validación permitió, en cambio, localizar cinco defectos de la capa de orquestación y persistencia, cuya corrección se especifica en este capítulo y cuya verificación se reporta en la sección 5.8.

Desde una perspectiva disciplinar, este trabajo posiciona a la Ingeniería en Informática como agente de transformación organizacional concreta, más allá de la implementación tecnológica aislada. La selección e integración de herramientas —n8n como orquestador de flujos, Mistral Cloud Chat como motor de extracción inteligente, y el ecosistema Google Workspace para persistencia y trazabilidad— exige un juicio de ingeniería que trasciende el conocimiento técnico individual: implica comprender el proceso de negocio, modelar sus restricciones, gestionar excepciones y diseñar para la resiliencia operativa.

En el plano del conocimiento, el trabajo distingue tres constructos que suelen confundirse: la proporción de casos que el sistema deriva por sí mismo a revisión humana, que en la ronda evaluada fue nula; la proporción de casos procesados sin defecto detectado por una verificación externa, que fue del 71,9 %; y la precisión extremo a extremo, entendida como la exactitud campo a campo del dato efectivamente persistido respecto del documento original. La distinción no es terminológica: un sistema puede exhibir una proporción elevada de resultados correctos y carecer por completo de capacidad para señalar los incorrectos, que es lo que el presente trabajo documenta. Asimismo, el trabajo documenta una condición de borde del diseño: la dependencia de la etapa de extracción respecto de la forma en que el documento es recibido por el flujo.

El aporte final de este trabajo es doble: metodológico, al ofrecer un protocolo reproducible de diagnóstico, diseño, implementación y evaluación de sistemas de hiperautomatización aplicable a contextos similares; y práctico, al proveer un modelo de arquitectura documentado y evaluado que puede ser adoptado, adaptado y escalado por organizaciones del sector comercial regional sin necesidad de partir desde cero.

Referencias

Bughin, J., Seong, J., Manyika, J., Chui, M., & Joshi, R. (2018). *Notes from the AI frontier: Modeling the impact of AI on the world economy*. McKinsey Global Institute. https://www.mckinsey.com/featured-insights/artificial-intelligence/notes-from-the-ai-frontier-modeling-the-impact-of-ai-on-the-world-economy

Chen, L.-C., Weng, H.-T., Pardeshi, M. S., Chen, C.-M., Sheu, R.-K., & Pai, K.-C. (2025). *Evaluation of prompt engineering on the performance*

of a large language model in document information extraction. Electronics, 14(11), 2145. https://doi.org/10.3390/electronics14112145

Costa, D. A. S., São Mamede, H., & Mira da Silva, M. (2022). *Robotic Process Automation (RPA) adoption: a systematic literature review. Engineering Management in Production and Services*, 14(2), 1–12. https://doi.org/10.2478/emj-2022-0012

Dagdelen, J., Dunn, A., Lee, S., Walker, N., Rosen, A. S., Ceder, G., Persson, K. A., & Jain, A. (2024). *Structured information extraction from scientific text with large language models*. Nature Communications, 15(1), 1418. https://doi.org/10.1038/s41467-024-45563-x

Davenport, T. H., & Kirby, J. (2016). *Only humans need apply: Winners and losers in the age of smart machines*. Harper Business.

Davenport, T. H., & Ronanki, R. (2018). Artificial intelligence for the real world. *Harvard Business Review, 96*(1), 108–116. https://hbr.org/2018/01/artificial-intelligence-for-the-real-world

Gartner. (2020). *Gartner top 10 strategic technology trends for 2020*. Gartner, Inc. https://www.gartner.com/en/documents/3976457

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

Groover, M. P. (2020). *Automation, production systems, and computer-integrated manufacturing* (5th ed.). Pearson.

Harmon, P. (2019). *Business process change: A business process management guide for managers and process professionals*. Morgan Kaufmann.

Hohpe, G., & Woolf, B. (2004). *Enterprise integration patterns*. Addison-Wesley.

Jurafsky, D., & Martin, J. H. (2023). *Speech and language processing* (3rd ed.). Stanford University. https://web.stanford.edu/~jurafsky/slp3/

Kleppmann, M. (2017). *Designing data-intensive applications*. O'Reilly Media.

Krieger, F., Drews, P., & Funk, B. (2023). *Automated invoice processing: Machine learning-based information extraction for long tail suppliers*. Intelligent Systems with Applications, 20, 200285. https://doi.org/10.1016/j.iswa.2023.200285

Lacity, M., & Willcocks, L. (2016). Robotic process automation at Telefónica O2. *MIS Quarterly Executive, 15*(1), 21 – 35.

Landis, J. R., & Koch, G. G. (1977). *The measurement of observer agreement for categorical data*. Biometrics, 33(1), 159–174.

Liu, P., Gao, W., Dong, W., Ai, L., Gong, Z., Huang, S., Li, Z., Hoque, E., Hirschberg, J., & Zhang, Y. (2024). *A survey on open information*

extraction from rule-based model to large language model. En *Findings of the Association for Computational Linguistics: EMNLP 2024* (pp. 9586–9608). Association for Computational Linguistics. https://doi.org/10.18653/v1/2024.findings-emnlp.560

Mistral AI. (2024). Mistral AI API documentation. https://docs.mistral.ai

n8n GmbH. (2024). n8n workflow automation platform. https://n8n.io

Pramod, D. (2022). *Robotic process automation for industry: adoption status, benefits, challenges and research agenda*. *Benchmarking: An International Journal, 29(5), 1562–1586. https://doi.org/10.1108/BIJ-01-2021-0033*

Westerman, G., Bonnet, D., & McAfee, A. (2014). *Leading digital: Turning technology into business transformation*. Harvard Business Review Press.

Xu, D., Chen, W., Peng, W., Zhang, C., Xu, T., Zhao, X., Wu, X., Zheng, Y., Wang, Y., & Chen, E. (2024). *Large language models for generative information extraction: a survey*. Frontiers of Computer Science, 18(6), 186357. https://doi.org/10.1007/s11704-024-40555-y

Anexos

Nota: los Anexos A y B transcriben de forma literal los prompts de sistema y los esquemas de salida configurados en el flujo de orquestación, obtenidos de su archivo de exportación. El registro detallado de la ronda de validación preliminar de mayo de 2026 no fue conservado en su totalidad, circunstancia declarada como limitación en el Capítulo 5. Los resultados de la validación ampliada del 17 de agosto de 2026 se reportan en el Capítulo 5. El material de reproducibilidad del trabajo se encuentra publicado en el repositorio https://github.com/XxExpleitxX/SAPP-TFI-UTN y archivado de forma permanente en Zenodo bajo el identificador digital de objeto https://doi.org/10.5281/zenodo.22148608. El conjunto contiene el flujo de n8n exportado, el corpus completo de veinte documentos comerciales, el protocolo de validación con el registro por caso de las treinta y cinco ejecuciones realizadas, de las cuales treinta y dos integran el cómputo de métricas, y con la línea de base del proceso manual y las capturas del entorno reproducidas en el Anexo C. El flujo se publica en el estado sobre el cual se realizaron las mediciones, sin incorporar las correcciones especificadas en el Capítulo 7, de modo que los resultados reportados resulten verificables. El archivo exportado no contiene credenciales: la plataforma de orquestación conserva únicamente referencias a ellas, que deben recrearse en la instancia de destino.

Anexo A: Prompts de sistema de las cadenas de extracción

Se transcriben a continuación, de forma literal, los prompts configurados en los nodos Basic LLM Chain del flujo de orquestación, obtenidos del archivo de exportación del workflow. Cada pipeline emplea un prompt propio.

Pipeline A — documentos PDF adjuntos. Mensaje de sistema:

```
Eres un experto en extraer pedidos de PDFs. Analiza el texto y devuelve **ÚNICAMENTE** el JSON válido según la estructura del Output Parser. No agregues explicaciones, no uses bloques de código (```json Responde solo con el objeto JSON puro.
```

Mensaje de usuario:

```
Extrae los datos del siguiente texto de pedido PDF:

{{ $json.text }}
```

Pipeline B — pedidos en el cuerpo del correo. Mensaje de sistema:

```
Actúa como un extractor de datos especializado en logística. Tu objetivo es analizar el cuerpo de un correo electrónico y extraer información sobre pedidos de productos.

Instrucciones estrictas:

Identificación: Determina si el texto contiene una solicitud de compra, pedido de mercadería o lista de artículos con cantidades.

Normalización:
  - Convierte cualquier cantidad escrita en palabras (ej: "cinco", "una docena") a su valor numérico (5, 12).
  - Limpia los nombres de los artículos para que solo incluyan el producto (ej: "bolsas de cemento" en lugar de "necesitaría que me mandes bolsas de cemento").

Formato de Salida: Debes responder únicamente con el objeto JSON definido en el esquema, sin texto adicional, explicaciones ni saludos.

Casos negativos: Si el correo es una consulta general, un saludo o no
```

```
contiene un pedido claro de artículos y cantidades, marca "es_pedido":
false y deja la lista de "pedido_detalles" vacía.
```

Mensaje de usuario:

```
Analiza el siguiente correo y extrae todos los productos pedidos con sus
cantidades.

Texto del correo:
{{ $json.html }}

Responde solo con el JSON según el schema requerido.
```

Se advierte una inconsistencia interna en el Pipeline B: el mensaje de sistema instruye devolver un campo es_pedido y una lista denominada pedido_detalles para los casos negativos, mientras que el esquema declarado en el Structured Output Parser no define ninguno de esos dos campos. La corrección de esta discrepancia se incorpora al conjunto de mejoras pendientes.

Anexo B: Esquemas de salida estructurada

Se transcriben los esquemas configurados en los nodos Structured Output Parser de cada pipeline.

Pipeline A — esquema declarado en notación JSON Schema:

```
{
  "type": "object",
  "properties": {
    "pedido": {
      "type": "object",
      "properties": {
        "numero_pedido": { "type": "string" },
```

```
        "fecha":            {            "type":            "string"            },
        "cliente":            {            "type":            "string"            }
      },
      "required":          ["numero_pedido",          "fecha",          "cliente"]
    },
    "items":                                                                    {
      "type":                                                                    "array",
      "items":                                                                   {
        "type":                                                                  "object",
        "properties":                                                            {
          "articulo":           {           "type":           "string"           },
          "cantidad":           {           "type":           "number"           },
          "unidad":            {            "type":            "string"            }
        },
        "required":                    ["articulo",                    "cantidad"]
      }
    }
  },
  "required":                          ["pedido",                          "items"]
}
```

Pipeline B — esquema declarado mediante ejemplo de salida:

```
{
  "pedidos":                                                                  [
    {    "producto":    "Cuadernos    A4    rayados",    "cantidad":    20    },
    {     "producto":     "Lápices     negros     HB",     "cantidad":     50     }
  ]
}
```

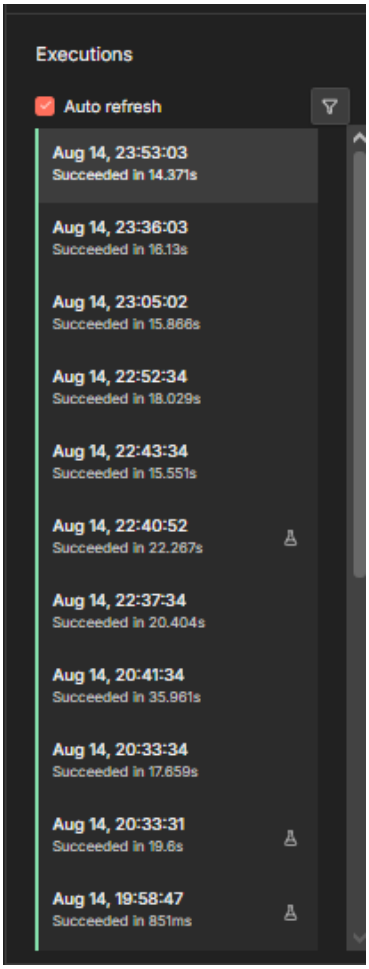
Etapa de normalización. El nodo Code in JavaScript del Pipeline A proyecta hacia la capa de persistencia únicamente el arreglo de líneas de ítem, con los campos artículo, cantidad y unidad. Los campos de cabecera del esquema —número de pedido, fecha y cliente— son

extraídos y validados, pero no se transfieren a la planilla de destino. El nodo homólogo del Pipeline B convierte el campo producto a cadena y el campo cantidad a número, e inserta una fila vacía cuando el arreglo resulta de longitud cero.

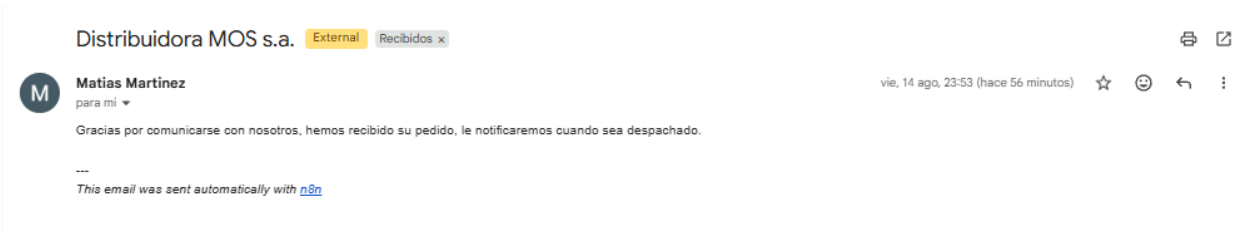
Condición de enrutamiento. El nodo IF evalúa la expresión Object.keys($binary).length > 0 sobre el elemento entregado por el trigger. La rama verdadera corresponde al Pipeline A y la falsa al Pipeline B. Esta condición explica el comportamiento documentado en el Capítulo 5: un documento PDF que no es recibido como propiedad binaria adjunta es enrutado hacia el pipeline de texto o, si alcanza la etapa de extracción sin binario disponible, activa el flujo de excepción.

Anexo C: Diagramas y capturas del sistema

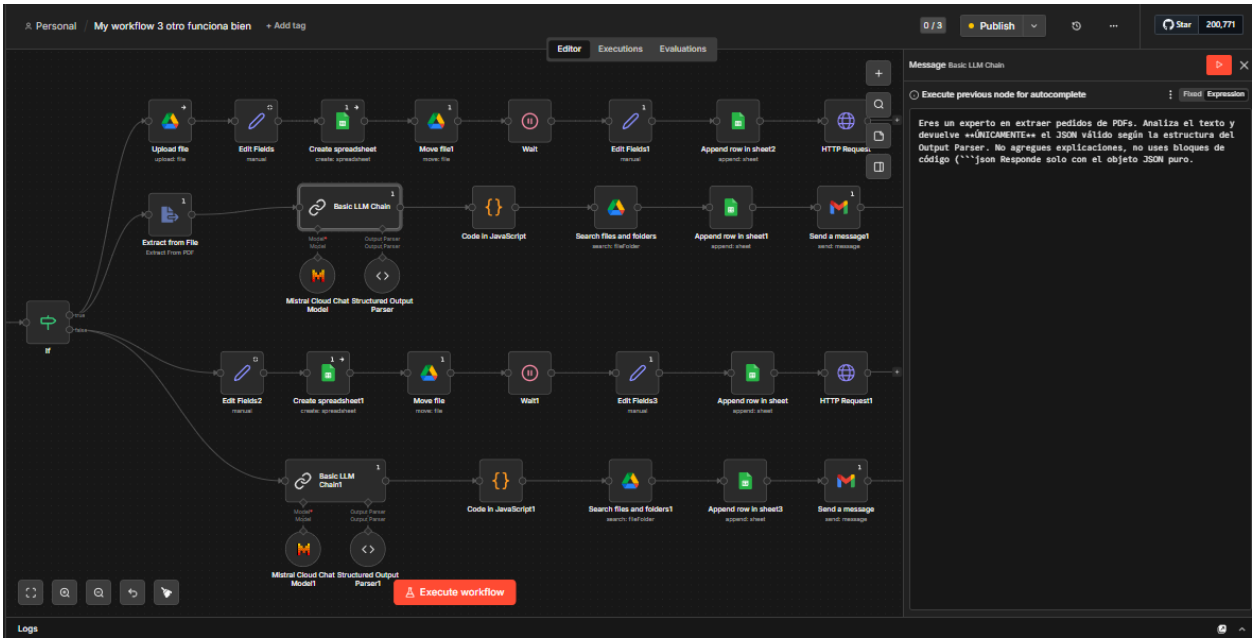
El diagrama de arquitectura general del sistema SAPP y la captura del flujo de automatización implementado en n8n se presentan en la sección 4.3 (Figura 1 y Figura 2, respectivamente). El prompt de sistema y el esquema de salida estructurada configurados en cada pipeline se transcriben de forma literal en los Anexos A y B. Se incorporan a continuación seis capturas del entorno de ejecución: el registro de ejecuciones de la plataforma de orquestación, la confirmación automática recibida por el destinatario de un pedido procesado exitosamente, el panel de configuración del nodo Basic LLM Chain del Pipeline A con el mensaje de sistema cargado, el esquema JSON configurado en el nodo Structured Output Parser del Pipeline A, el panel de ejecución del nodo Basic LLM Chain con la salida estructurada del modelo para un caso real del corpus, y el esquema configurado en el nodo Structured Output Parser del Pipeline B.



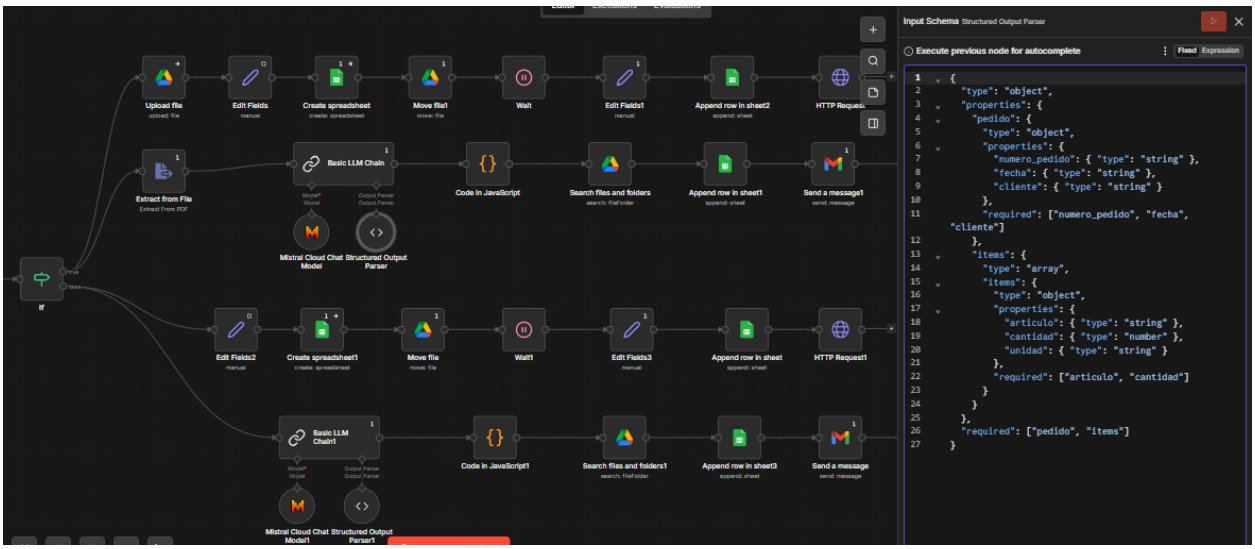
Captura C.1. Registro de ejecuciones de la plataforma n8n durante la ronda de validación, con marca de tiempo, duración y resultado de cada corrida.



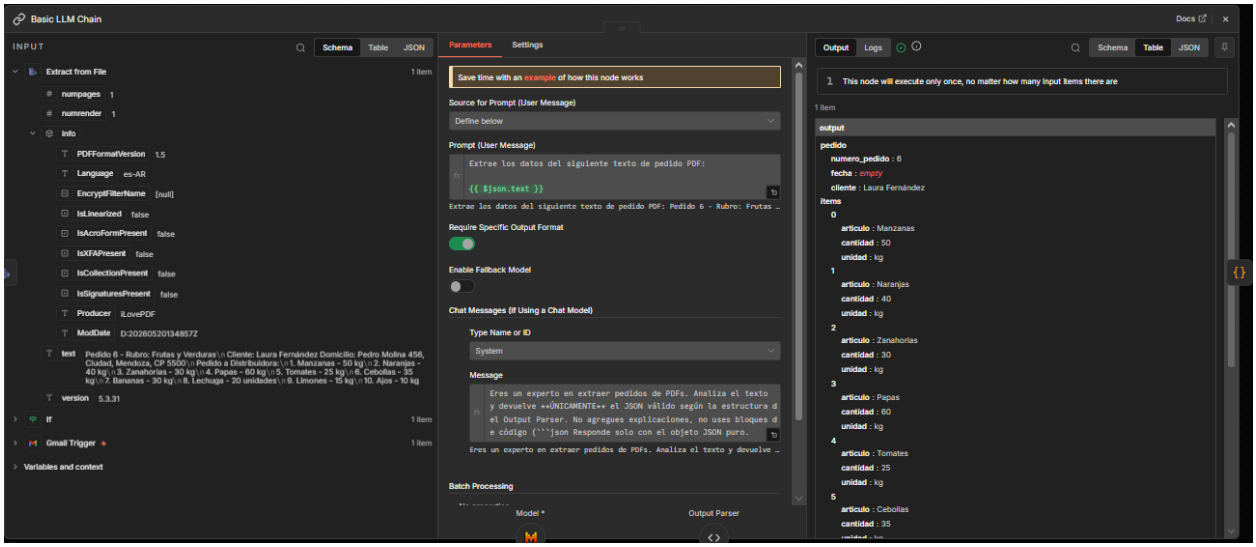
Captura C.2. Confirmación automática recibida por el destinatario de un pedido procesado exitosamente por el sistema SAPP.



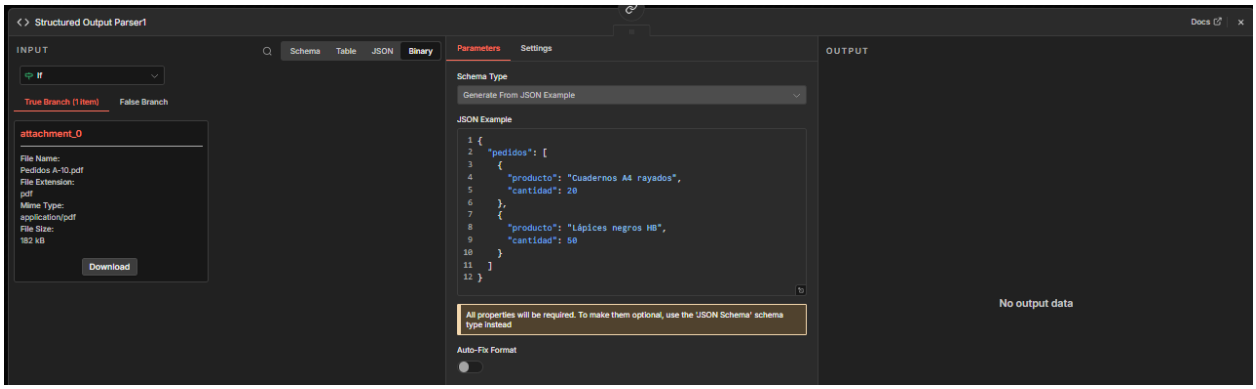
Captura C.3. Panel de configuración del nodo Basic LLM Chain (Pipeline A), con el mensaje de sistema cargado. El texto coincide con la transcripción del Anexo A.



Captura C.4. Esquema JSON configurado en el nodo Structured Output Parser del Pipeline A, coincidente con la transcripción del Anexo B.



Captura C.5. Panel de ejecución del nodo Basic LLM Chain del Pipeline A, con el mensaje de sistema, el mensaje de usuario y la salida estructurada del modelo. Documenta tres comportamientos verificados: el campo fecha se devuelve vacío ante su ausencia en el documento, sin que el modelo fabrique un valor; los campos de cabecera numero_pedido y cliente se extraen correctamente; y el campo unidad se extrae para cada ítem. Los tres se pierden antes de la planilla, conforme a lo descrito en el Capítulo 5.



Captura C.6. Esquema configurado en el nodo Structured Output Parser del Pipeline B. El esquema declara un arreglo de pedidos con los campos producto y cantidad, y no contempla el campo de unidad de medida presente en el esquema del Pipeline A. Se observa asimismo que el esquema se define mediante la modalidad de generación a partir de un ejemplo en formato JSON, en la cual la totalidad de las propiedades resulta obligatoria, según advierte la propia plataforma.

Anexo D: Registro de excepciones de la validación preliminar

En la Tabla 9 se consigna el caso de excepción registrado durante la ronda de validación preliminar de mayo de 2026. Durante la validación ampliada del 17 de agosto de 2026, reportada en el Capítulo 5, no se registraron excepciones atribuibles al diseño del sistema en ninguno de los treinta y dos casos computados. El caso CP-12a de esa ronda constituyó una excepción de configuración del entorno —el nodo de traslado del archivo apuntaba a una carpeta sin permisos de acceso— y no una limitación del sistema, por lo que se excluyó del cómputo de métricas.

Tabla 9

Registro de excepciones de la validación preliminar

Fecha	Tipo de documento	Motivo de la excepción	Resolución
27/05/2026	PDF adjunto	El documento no fue recibido como archivo binario adjunto; el nodo Extract From File no pudo acceder al PDF	Derivado a revisión manual

Nota. Elaboración propia a partir del registro de ejecuciones.